基于中文社交媒体文本的领域情感词典构建方法研究*

蒋翠清[1,2]　郭轶博[1]　刘　尧[1]
[1](合肥工业大学管理学院　合肥 230009)
[2](过程优化与智能决策教育部重点实验室　合肥 230009)

摘要: 【**目的**】从社交媒体用户生成内容中发现未知情感词，构造领域情感词典，应用于汽车评论的情感分析。【**方法**】选取 HowNet 情感词典作为种子，以实际汽车评论作为语料，分别利用 PMI 和 Word2Vec 算法识别新词情感极性，根据集成规则对二者识别结果综合判定，通过情感分类实验对比显示本文算法的有效性。【**结果**】按照该方法构造的情感词典准确率比 HowNet 情感词典提高 21.6%，较分别使用 PMI 和 Word2Vec 算法构建的词典分别提升 3.7%和 2.1%，同时正面、负面情感词数量均有大幅增加。【**局限**】语料来源单一，应用于其他领域具有一定局限性。【**结论**】该方法构造的情感词典可有效应用于社交媒体文本情感分析。

关键词: 社交媒体　情感分析　情感词典　PMI　Word2Vec
分类号: TP391
DOI: 10.11925/infotech.2096-3467.2018.0578

1　引　言

情感词典是社交媒体文本情感分析的重要技术手段[1-2]，情感词典的表现效果很大程度取决于情感词的选择。一个拥有准确情感倾向同时能够覆盖大部分情感词的情感词典，在文本的情感分类、主题分类等任务中能够获得较高的准确率[3]。随着社交媒体内容的多元化发展，情感词典的领域特性日益明显，新词、专有名词不断涌现，传统的通用情感词典由于覆盖度低无法涵盖领域依赖的情感词。因此，基于种子词进行领域内自动扩展构建情感词典的方法成为当前一项热门研究内容，其核心问题在于如何准确判别未知新词的情感极性。本文提出一种面向中文社交媒体汽车领域环境下情感词典自动扩建方法，利用点互信息 PMI 和词向量 Word2Vec 算法分别判断候选词的情感极性，再根据本文提出的集成规则对情感词进行最终倾向判别，从而快速构建出具有较好分类效果的领域情感词典。

2　研究现状

情感词典构建方法主要分为人工标注和自动扩展两种方式。早期情感词典多是由专家标注情感词人工构建而成，例如英文领域著名的 WordNet 词典[4]、General Inquirer(GI)词典[5]、SentiWordNet[4]词典、Opinion Lexicon 等，中文领域常见的如知网情感库 HowNet 词典[6]、中国台湾大学通用中文情感词典 NTUSD[7]等。人工标注构建的方法耗时费力，只能识别有限的情感词，而且不能很好地适应社交媒体环境下文本的情感分析任务。一方面，社交媒体环境下文本新词多，词语多义现象普遍，传统的情感词典很难

通讯作者：蒋翠清，ORCID: 0000-0001-6492-4550，E-mail: jiangcuiq@163.com。

*本文系国家自然科学基金项目“基于社交媒体用户生成内容的产品创新需求发现方法研究”(项目编号: 71571059)、国家自然科学基金重点项目“大数据环境下的微观信用评价理论与方法研究”(项目编号: 71731005)和安徽省教育厅高校人文社会科学重大研究项目“社会媒体环境下企业舆情演化机理与管控研究”(项目编号: SK2014ZD054)的研究成果之一。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

覆盖到新的情感词，同时也无法甄别早期情感词的新情感倾向变化情况。另一方面，社交媒体的文本内容具有领域特征，而早期的情感词典只包含通用情感词，无法适应社交媒体多领域的特点。文献[8]发现利用通用的情感词典进行特定领域的情感分析，可能会造成严重的信息误判，因此无法胜任社交媒体环境下用户生成内容的情感分析任务。

对专家标注的情感词作为种子进行自动扩展得到领域情感词典是目前主流的做法。扩展的核心问题是衡量候选词与种子词之间的距离，从而计算新词的情感极性。目前，自动扩展的构建方法可以分为基于词间共现概率法和语义相似度衡量法两种。词间共现(Co-occurrence)概率是一种统计量，可用于发现情感词。基于这种思想的方法有点互信息 PMI(Pointwise Mutual Information)[9]、SO-PMI(Semantic Orientation-Pointwise Mutual Information)[10]等。这种方法的原理是通过使用一个足够大的语料库计算两个词或词组之间的文本共现率，从而衡量未知情感极性的新词与已知情感极性的种子词之间的紧密程度。文献[11]面向英文社交平台股票领域，将候选词分为 4 类 8 个集合，使用 PMI 算法计算不同候选词和不同情感词典情况下扩展得到的情感词典。文献[12]以图书评论作为语料，人工选取 7 类情感种子词，利用改进的 SO-PMI 算法构建一个面向中文图书评论领域的情感词典并取得一定效果。文献[13]提出一个两阶段的领域情感词典构建方法，其中第一阶段使用 PMI 计算每个新词的情感倾向。但是利用共现情况或者互信息衡量两个词的联系紧密程度，需要依赖情感词在语料库中的分布规律。无法保证大规模较为完整的语料库时，若某一情感词在一条语料下出现次数较多而在其他语料下出现次数很少甚至不出现，这样将无法计算候选词与种子词之间的情感值。

利用语义衡量候选词与种子词之间的距离是另一种主要的识别新词情感极性的方法。早期主要通过 HowNet 计算语义相似度。这种方法也是通过选择一些已知情感词作为种子，然后衡量新词与种子词之间的紧密程度。与 PMI 方法使用共现率衡量不同，这种方法是基于知网的相似度计算。文献[14]使用 HowNet 的语义相似度计算一个词与正面词集和负面词集的相似度差值作为新词的情感极性。但是这种计算语义相似度的方法严重依靠知网词典的完善性。Word2Vec[15]是一种通过神经网络语言模型将语料库中的词映射到 N 维向量空间的高效工具，利用大量的文本阅读充分学习语料库中全局的语法信息和语义信息，然后通过神经网络训练的模型将词映射成固定维度的向量，使得将对文本的处理简化为 N 维空间向量的运算。近年，Word2Vec 越来越多地应用于文本分析相关领域。基于 Word2Vec 的情感词典扩建方法能够同时考虑语义信息以及词语的领域特征，在处理不同文字、但是在相似语境下的词具有明显的优势。文献[16]发现，通过这种方法映射的向量计算出余弦相似度能够很好地反映词之间的语义关系程度。文献[17]对情感进行 10 种维度细粒度的划分，使用大规模的语料利用 Word2Vec 构建多维度的跨领域通用情感词典。文献[18]通过人工筛选和 Word2Vec 词聚类构建情感词典，并通过实验证明该词库比一般情绪词表在准确率上有提升。但具有相同语义的词并非带有相同的情感，另外也需要保证语义相似度计算的准确率，因为有些语义非常相似的词但余弦相似性可能并不高，这依赖于 Word2Vec 内部的参数设置。

综上，使用点互信息和语义相似度均可以判别候选词的情感极性。但是 PMI 和 Word2Vec 算法本身需要满足严格的条件，前者依赖情感词在语料库中的分布规律，需要完备的语料库作为支撑；后者依赖神经网络内部的参数调整以保证准确表达并计算语义。为克服这两种方法的局限性，本文提出一种融合 PMI 和 Word2Vec 识别的领域情感词典扩建方法。

3　基于社交媒体文本的领域情感词典扩展框架

本文构建中文社交媒体环境下基于 PMI 和 Word2Vec 混合识别的领域情感词典自动扩展框架，如图 1 所示。该框架包含两个子过程:

(1) 数据准备阶段，这一过程主要是将社交媒体环境下半结构化、非结构化的用户生成内容转化为结构化的、有利于下一步分析使用的文本数据，具体包括数据爬取、数据预处理、词性标注三个环节。此阶段产出从语料库中提取的候选词。

(2) 情感词典扩建阶段，这一过程是进行情感词

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

的识别并构建最终的词典，具体包括利用 PMI 计算共现率和利用 Word2Vec 计算语义相似度分别判断候选词的极性，然后通过集成规则将候选词分类到相应的集合中，最终构造出领域情感词典。

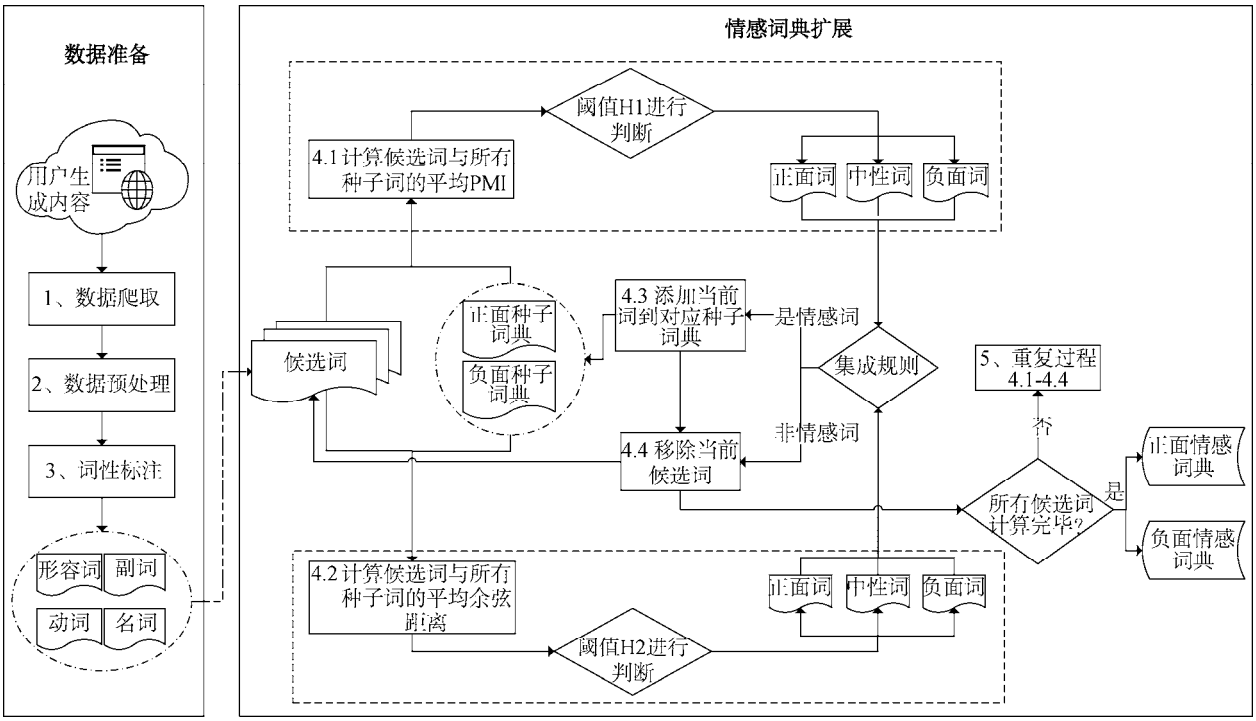


图 1　基于社交媒体文本的领域情感词典构建框架

3.1　提取候选词

形容词和副词具有天然的情感极性，因此多数现有文献[12,19]在构建情感词典时将形容词和副词作为潜在的情感词。但是部分的动词和名词也是拥有情感的，这种特点在领域环境下尤为突出。如“这款车经常漏油!”，此句中的动词“漏油”是一个明显的负面情感词。再比如: “真奇葩！每次启动都是龟速！”，此句中的名词“奇葩”和“龟速”的情感极性都是负面的。文献[11]证明了英文环境下股票领域和政治领域词性的不同会带来情感词典表现差异，但是中文和英文具有明显的语言差异，尚没有研究文献表明中文环境下汽车领域情感词的词性对情感词典的效果具有明显差异。笔者认为在中文环境下情感词的词性会影响情感词典的表现。因此，在本文提出的情感词典自动扩展框架中，当进行词性标注后只保留名词、动词、形容词和副词这 4 类词作为潜在的情感词，候选词集使用这 4 类词的组合: 形容词+副词、形容词+副词+动词、形容词+副词+名词、形容词+副词+动词+名词。

3.2　基于 PMI 的情感极性判别

PMI 可以通过计算两个词或词组之间的文本共现率从而衡量它们之间的相似性[9]，因此使用 PMI 计算候选词与种子词之间的共现率。假设用 w_1, w_2 分别代表两个词或词组，则 PMI 的计算如公式(1)所示。

$$PMI(w_1, w_2) = \log_2 \frac{p(w_1, w_2)}{p(w_1)p(w_2)} \qquad (1)$$

其中，$p(w_i)$ 表示 w_i 在语料库中出现的概率，$p(w_1, w_2)$ 表示 w_1, w_2 在语料库中同时出现的概率，$PMI(w_1, w_2)$ 表示 w_1, w_2 的关联程度。通过 PMI 公式计算候选词与种子词典里所有正面种子和负面种子的平均关联程度，由此计算出候选词 *word* 的情感分数，如公式(2)所示。

$$SentiScore(word) = \frac{1}{N_{pos}} \sum_{i=1}^{N_{pos}} PMI(word, posSeed_i) - \frac{1}{N_{neg}} \sum_{j=1}^{N_{neg}} PMI(word, negSeed_j) \qquad (2)$$

其中，$posSeed_i$ 和 $negSeed_j$ 分别表示种子词典中

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

的正面情感词和负面情感词，对应的 N_{pos} 和 N_{neg} 分别表示正面情感词个数和负面情感词个数。因此，使用 PMI 判断候选词 *word* 情感极性的表达式如公式(3)所示。

$$polarity(word)=\begin{cases}positive & SentiScore(word)>H_1\\ neutral & -H_1<SentiScore(word)<H_1\\ negative & SentiScore(word)<-H_1\end{cases} \tag{3}$$

其中，阈值 H_1 是一个非负数。当计算的候选词情感得分大于 H_1 时，该候选词被识别为正面词，添加到正面种子词典；当情感得分小于 $-H_1$ 时，被识别为负面词，对应添加到负面种子词典；当情感得分介于 $-H_1$ 和 H_1 时，该候选词被识别为中性词。显然，阈值 H_1 越小，最终的情感词典规模越大，但是也有可能带来更多噪音，影响情感分类的准确率。因此，本文通过敏感性分析调整最佳阈值 H_1。

3.3　基于 Word2Vec 的情感极性判别

Word2Vec 技术能够将语料库中的每个词映射成固定维度的向量，当使用这种方法构造的词向量在计算两个词之间的夹角余弦距离时，向量的夹角余弦值反映两个词之间的语义相似度[20-21]。假设用 w_1, w_2 分别代表两个词或词组，利用 Word2Vec 将词映射成 n 维向量 $w_1=(x_1, x_2\cdots, x_n), w_2=(y_1, y_2\cdots, y_n)$。通过夹角余弦公式计算候选词与种子词典中所有正面种子和负面种子的平均语义相似度，从而得出候选词 *word* 的情感得分，如公式(4)–公式(5)所示。

$$\cos(w_1, w_2)=\frac{\sum_{i=1}^{n}x_i y_i}{\sqrt{\sum_{i=1}^{n}x_i^2}\sqrt{\sum_{i=1}^{n}y_i^2}} \tag{4}$$

$$SentiScore(word)=\frac{1}{N_{pos}}\sum_{i=1}^{N_{pos}}\cos(word, posSeed_i)-\frac{1}{N_{neg}}\sum_{j=1}^{N_{neg}}\cos(word, negSeed_j) \tag{5}$$

其中，计算向量 w_1, w_2 的夹角余弦，亦即 w_1, w_2 两个词之间的语义相似度。公式(5)计算在使用语义相似度的情况下候选词 *word* 的情感分数。与公式(2)中变量符号表达意义相同，此处 $\{posSeed_i \mid i=1,2\cdots, N_{pos}\}$ 和 $\{negSeed_j \mid j=1,2\cdots, N_{neg}\}$ 分别表示正面种子词集和负面种子词集。基于此，使用语义相似度判断候选词 *word* 的情感极性如公式(6)所示。

$$polarity(word)=\begin{cases}positive & SentiScore(word)>H_2\\ neutral & -H_2<SentiScore(word)<H_2\\ negative & SentiScore(word)<-H_2\end{cases} \tag{6}$$

其中，参数 H_2 是一个非负数。与利用 PMI 判断候选词的情感极性类似，当阈值 H_2 越大，则识别的情感词数量越少；当阈值 H_2 越小，则识别的情感词数量越多，但是也会识别出较多不相关的情感词，从而造成情感词典表现效果的下降。因此，需要通过敏感性分析设置合理的阈值 H_2。

3.4　基于集成学习规则的情感极性判别

集成学习是一种常用且有效的机器学习方法，基本思想是先训练构造出一组基学习器，然后设计特定的规则将基学习器的结果进行融合作为最终的模型输出[20]。假设有 T 个独立分类器 $g_i(x), 1<i<T$，真实模型为 $f(x)$。针对二分类问题记 $y\in\{-1,1\}$，若每个基分类器错误率为 ε，则 $p(g_i(x)\neq f(x))=\varepsilon$。假设融合规则是最简单的投票法，则最终模型为 $G(x)=sign(\sum_{i=1}^{T}g_i(x))$，最终集成模型的错误率为 $P(G(x)\neq f(x))=\sum_{k=0}^{\lfloor T/2\rfloor}\binom{T}{k}(1-\varepsilon)^k\varepsilon^{T-k}\leqslant\exp(-\frac{1}{2}T(1-2\varepsilon)^2)$。因此，集成模型的错误率随着基分类器的个数增加呈指数级下降。针对分类问题，集成学习中基分类器结果融合规则有多种。文献[21]最早提出 k 个分类器进行 n 元分类的 5 种融合集成规则 Max_Rule, Min_Rule, Product_Rule, MajorityVote_Rule 和 Sum_Rule，这 5 种经典的集成规则被证明简单且有效，其中的投票规则应用最为广泛[22]。此后的文献提出了一些改进，如文献[23]考虑新数据与已分类数据的距离 D_i，计算单元变为 $p(Y_i)/D_{ik}$；文献[24]考虑每种分类结果的 AUC 值，计算单元设计为 $p(Y_i)\times AUC_{area_k}$。表 1 整理上述文献集成模型设计的融合规则。

传统的投票规则 Majority Vote Rule 将每个基分类器的权重都视为单位 1，直接比较每个类标 Y_i 获得的

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

投票数，从而决定集成模型的分类结果为获得票数最多的类标。本文的分类背景是将一个未知情感的候选词分为正面词、负面词和中性词三类。显然根据生活认知，在足够大的文本语料中，正面词、负面词和中性词出现的频率不同，从而将一个候选词分成正面、中性、负面三种结果的概率也不同，因此投票规则需要考虑不同分类概率对融合结果造成的影响。本文将基于 PMI 的情感极性判别模型和基于 Word2Vec 的情感极性判别模型作为两个基分类器 C_1 和 C_2，对于分类结果 *negative*，*neutral* 和 *positive*，记 $y \in \{Y_{-1}, Y_0, Y_1\}$，$P(Y_{-1}), P(Y_0), P(Y_1)$ 分别表示其分类概率。首先需要提出如下两个假设。

表 1　集成模型融合规则

参考文献	集成规则	策略
(Kittler 等, 1998)[21]	Max Rule	$\max\left\{\max_{C_1,C_2,\ldots,C_K} P(Y_1), \max_{C_1,C_2,\ldots,C_K} P(Y_2), \cdots, \max_{C_1,C_2,\ldots,C_K} P(Y_n)\right\}$
	Min Rule	$\max\left\{\min_{C_1,C_2,\ldots,C_K} P(Y_1), \min_{C_1,C_2,\ldots,C_K} P(Y_2), \cdots, \min_{C_1,C_2,\ldots,C_K} P(Y_n)\right\}$
	Product Rule	$\max\left\{\prod_{C_1,C_2,\ldots,C_K} P(Y_1), \prod_{C_1,C_2,\ldots,C_K} P(Y_2), \cdots, \prod_{C_1,C_2,\ldots,C_K} P(Y_n)\right\}$
	Majority Vote Rule	$\max\left\{\sum_{C_1,C_2,\ldots,C_K} Y_1, \sum_{C_1,C_2,\ldots,C_K} Y_2, \cdots, \sum_{C_1,C_2,\ldots,C_K} Y_n\right\}$
	Sum Rule	$\max\left\{sum_{C_1,C_2,\ldots,C_K} P(Y_1), sum_{C_1,C_2,\ldots,C_K} P(Y_2), \cdots, sum_{C_1,C_2,\ldots,C_K} P(Y_n)\right\}$
(Sun 等, 2015)[23]	Max Distance Rule	$\max\left\{\max_{C_1,C_2,\ldots,C_K} \frac{P(Y_1)}{D_{i1}+1}, \max_{C_1,C_2,\ldots,C_K} \frac{P(Y_2)}{D_{i2}+1}, \cdots, \max_{C_1,C_2,\ldots,C_K} \frac{P(Y_n)}{D_{in}+1}\right\}$
	Min Distance Rule	$\max\left\{\min_{C_1,C_2,\ldots,C_K} \frac{P(Y_1)}{D_{i1}+1}, \min_{C_1,C_2,\ldots,C_K} \frac{P(Y_2)}{D_{i2}+1}, \cdots, \min_{C_1,C_2,\ldots,C_K} \frac{P(Y_n)}{D_{in}+1}\right\}$
	Product Distance Rule	$\max\left\{\prod_{C_1,C_2,\ldots,C_K} \frac{P(Y_1)}{D_{i1}+1}, \prod_{C_1,C_2,\ldots,C_K} \frac{P(Y_2)}{D_{i2}+1}, \cdots, \prod_{C_1,C_2,\ldots,C_K} \frac{P(Y_n)}{D_{in}+1}\right\}$
	Majority Vote Distance Rule	$\max\left\{\sum_{C_1,C_2,\ldots,C_K} \frac{Y_1}{D_{i1}+1}, \sum_{C_1,C_2,\ldots,C_K} \frac{Y_2}{D_{i2}+1}, \cdots, \sum_{C_1,C_2,\ldots,C_K} \frac{Y_n}{D_{in}+1}\right\}$
	Sum Distance Rule	$\max\left\{sum_{C_1,C_2,\ldots,C_K} \frac{P(Y_1)}{D_{i1}+1}, sum_{C_1,C_2,\ldots,C_K} \frac{P(Y_2)}{D_{i2}+1}, \cdots, sum_{C_1,C_2,\ldots,C_K} \frac{P(Y_n)}{D_{in}+1}\right\}$
(Li 等, 2016)[24]	Weighted Max Rule	$\max\left\{\max_{C_1,C_2,\ldots,C_K} P(Y_1)\times AUC_{area_i}, \max_{C_1,C_2,\ldots,C_K} P(Y_2)\times AUC_{area_i} \cdots, \max_{C_1,C_2,\ldots,C_K} P(Y_n)\times AUC_{area_k}\right\}$
	Weighted Min Rule	$\max\left\{\min_{C_1,C_2,\ldots,C_K} P(Y_1)\times AUC_{area_i}, \min_{C_1,C_2,\ldots,C_K} P(Y_2)\times AUC_{area_i} \cdots, \min_{C_1,C_2,\ldots,C_K} P(Y_n)\times AUC_{area_k}\right\}$
	Weighted Product Rule	$\max\left\{\prod_{C_1,C_2,\ldots,C_K} P(Y_1)\times AUC_{area_i}, \prod_{C_1,C_2,\ldots,C_K} P(Y_2)\times AUC_{area_i}, \cdots, \prod_{C_1,C_2,\ldots,C_K} P(Y_n)\times AUC_{area_k}\right\}$
	Weighted Majority Vote Rule	$\max\left\{\sum_{C_1,C_2,\ldots,C_K} P(Y_1)\times AUC_{area_i}, \sum_{C_1,C_2,\ldots,C_K} P(Y_2)\times AUC_{area_i}, \cdots, \sum_{C_1,C_2,\ldots,C_K} P(Y_n)\times AUC_{area_k}\right\}$
	Weighted Sum Rule	$\max\left\{sum_{C_1,C_2,\ldots,C_K} P(Y_1)\times AUC_{area_i}, sum_{C_1,C_2,\ldots,C_K} P(Y_2)\times AUC_{area_i}, \cdots, sum_{C_1,C_2,\ldots,C_K} P(Y_n)\times AUC_{area_k}\right\}$

(注：$C_1, C_2, \cdots, C_k$ 表示 k 个分类器，$Y_1, Y_2, \cdots, Y_n$ 表示 n 种分类类标，$P(Y_i)$ 表示分类器的分类结果是 Y_i 的概率。)

假设 1：$P(Y_{-1}) < P(Y_0)$，$P(Y_1) < P(Y_0)$

假设 2：若 Y_{-1} 和 Y_1 获得票数相同，则将分类结果取 Y_0

提出假设 1 是因为在一个足够大的语料库中正面词、负面词出现的频率要小于中词性，从而分类器对某个候选词分成正面词、负面词的概率小于分成中性词的概率。提出假设 2 是因为在 k 个分类器，n 元分类的背景下，若票数相同需要事先人工定义处理规则。在本文两个分类器下且 *positive* 和 *negative* 获得票数相同时，在两个基分类器都是有效可靠的前提下，此时取分类结果为“折中的”Y_0。至此，本文提出一种改进的投票规则 Adjusted Majority Vote Rule (AMVR)，其分类策略如公式(7)所示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

$$\max\left\{\sum_{C_1,C_2} Y_{-1}/P(Y_{-1}),\ \sum_{C_1,C_2} Y_0/P(Y_0),\ \sum_{C_1,C_2} Y_1/P(Y_1)\right\} \quad (7)$$

在 Adjusted Majority Vote Rule 规则下，两个分类器的融合规则是计算每个类标所获投票数与每个类标的分类概率乘积，取结果最大的所在类标作为最终分类结果。例如当 $C1$ 和 $C2$ 的分类结果分别是 $Y1$ 和 $Y0$(不区分 $C1$ 和 $C2$ 具体是哪个基分类器)，说明 $Y1$ 与 $Y0$ 所获投票数相同，再由假设 1 知 $\sum_{C_1,C_2} Y_1/P(Y_1) < \sum_{C_1,C_2} Y_0/P(Y_0)$，所以最终分类结果是正面词。

4　实验与结果分析

4.1　数据与预处理

从汽车之家的论坛频道[25]获取评论作为汽车领域用户生成内容的语料库，删除只有标点符号而无文字的评论后共计 309 937 条。为构造测试集，从语料库中随机抽取 5 000 条评论进行人工标注，标注过程请三位研究生共同参与。本文关注情感词典进行二分类任务的准确率，因此删除标注结果里的中性和无关评论。为剔除数据不平衡对分类带来的影响，只保留等量的正面和负面评论，最终测试集包含正面评论和负面评论各 600 条。使用 HowNet 情感词典作为种子词典，其中褒义词数 836 个，贬义词 1 254 个。

数据预处理方面，使用 Python 调用 jieba[26]分词包进行中文分词和词性标注，加入搜狗输入法词库频道的汽车词库[27]作为用户词典。词性标注环节保留名词、动词、形容词和副词作为候选词，其中名词的数量大约是其他三类候选词总数的两倍多。因为有些名词很少含有情感，为了提高实验的效率，将专有名词、地点名词、人物名词从名词候选词集中进行剔除。将候选词集按照词性分成 4 组，每组候选词的词性和数量如表 2 所示。

表 2　候选词集列表

序号	候选词集词性	符号标记	数量(个)
1	形容词+副词	AR	2 095
2	形容词+副词+动词	ARV	8 039
3	形容词+副词+名词	ARN	9 032
4	形容词+副词+动词+名词	ARVN	14 976

4.2　实验设计

将不同方法构造的情感词典在测试集上进行情感分类实验，通过对比情感词典的表现差异以验证方法的有效性。利用 SentiStrength[28]情感分析工具进行文本情感二分类任务，评价指标选择准确率(Accuracy)。首先需要确定基于 PMI 和基于 Word2Vec 扩展方法的最优候选词集和阈值。这一过程设计 9 组实验，每组的情感词典如表 3 所示，对每组在测试集上的分类准确率为标准进行敏感性分析，从中获得准确率最高情况下的参数组合。

表 3　确定最优参数的实验组设计

序号	基准词典	扩展方法	候选词集词性	情感词典标记
1	HowNet	——	——	HowNet
2	HowNet	PMI	AR	PMI_HowNet_AR
3	HowNet	PMI	ARV	PMI_HowNet_ARV
4	HowNet	PMI	ARN	PMI_HowNet_ARN
5	HowNet	PMI	ARVN	PMI_HowNet_ARVN
6	HowNet	Word2Vec	AR	Word2Vec_HowNet_AR
7	HowNet	Word2Vec	ARV	Word2Vec_HowNet_ARV
8	HowNet	Word2Vec	ARN	Word2Vec_HowNet_ARN
9	HowNet	Word2Vec	ARVN	Word2Vec_HowNet_ARVN

表 4 和表 5 分别表示在基于 PMI 扩展方法下和在基于 Word2Vec 扩展方法下不同的候选词集与阈值 H_1、H_2 参数组合时的情感词典分类准确率。从表 4 和表 5 中选取准确率达到最优时的 H_1 与候选词集组合，H_2 与候选词集组合，再按照 3.4 节方法构建融合 PMI 和 Word2Vec 方法的情感词典。

4.3　结果分析

表 4 和表 5 分别显示 H_1 和 H_2 取不同值的情况下，基于 PMI 生成情感词典的分类准确率。从表 4 可以看出，当阈值 H_1 从 0.1 上升到 0.3 再上升到 1.0 时，所有候选词集构建的情感词典分类准确率先增加后减小。这是因为当 H_1 较小时，情感词典包含的词的数量增多，引入噪音，所以准确率降低；随着 H_1 变大，噪音减少，但是被识别的情感词数量减少，造成情感词典覆盖率不全，因此准确率也降低。同时可以看出，情感词典中词性的不同对于情感词典的分类效果具有明显的差异。阈值 H_1 固定情况下，候选词集为形容词+副词+动词+名词时所构造的情感词典，即 PMI_HowNet_ARVN，其分类准确率要优于候选词集为形容词、副词、动词、名词的其他组合所构造的情感词典。另外，

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

无论使用何种组合的候选词，对通用词典进行扩展后得到的情感词典，其表现效果都优于没有扩展的情感词典 HowNet。这也说明通用情感词典表现效果在特定文本领域环境下要明显劣于领域词典的分类表现，这正是领域情感词典构建的意义所在。表 5 反映的规律与表 4 类似。当 H_2 大于 0.8 时，纵向来看所有情感词典的准确率性不再变化，同时横向来看，使用 ARVN 构造的情感词典与使用其他候选词集构造的情感词典准确率也不再变化。这是由于 Word2Vec 是计算不同词语之间的语义相似度再利用阈值进行判断正负的。当阈值 H_2 大到某一程度时，由于语料库中词语之间的语义相似性程度本身高于某个临界值，所识别的词语已经固定，即使 H_2 变大，也不会减少识别的情感词数量，最终表现为情感词典的准确率不再变化。

表 6 通过 5 组对比实验展示不同扩展方法生成的情感词典准确率。

表 4　不同 H_1 取值对基于 PMI 生成情感词典分类准确率

	HowNet	PMI_HowNet_AR	PMI_HowNet_ARV	PMI_HowNet_ARN	PMI_HowNet_ARVN
H_1=0.1	0.646	0.699	0.731	0.749	0.770
H_1=0.2	0.646	0.762	0.781	0.790	0.809
H_1=0.3	0.646	0.787	0.802	0.810	0.825
H_1=0.4	0.646	0.775	0.793	0.818	0.818
H_1=0.5	0.646	0.745	0.772	0.800	0.807
H_1=0.6	0.646	0.732	0.758	0.790	0.799
H_1=0.7	0.646	0.715	0.739	0.782	0.790
H_1=0.8	0.646	0.710	0.731	0.775	0.781
H_1=0.9	0.646	0.702	0.724	0.769	0.778
H_1=1.0	0.646	0.698	0.715	0.765	0.776

表 5　不同 H_2 取值对基于 Word2Vec 生成情感词典分类准确率

	HowNet	Word2Vec_HowNet_AR	Wordd2Vec_HowNet_ARV	Word2Vec_HowNet_ARN	Word2Vec_HowNet_ARVN
H_2=0.1	0.646	0.791	0.804	0.815	0.829
H_2=0.2	0.646	0.815	0.821	0.838	0.841
H_2=0.3	0.646	0.793	0.795	0.828	0.834
H_2=0.4	0.646	0.719	0.733	0.779	0.791
H_2=0.5	0.646	0.662	0.677	0.703	0.722
H_2=0.6	0.646	0.637	0.643	0.660	0.682
H_2=0.7	0.646	0.633	0.639	0.642	0.652
H_2=0.8	0.646	0.630	0.630	0.633	0.636
H_2=0.9	0.646	0.624	0.624	0.624	0.624
H_2=1.0	0.646	0.624	0.624	0.624	0.624

表 6　不同方法生成词典准确率对比

词典	正面词个数	负面词个数	正面准确率	负面准确率	平均准确率
HowNet	836	1 254	0.590	0.702	0.646
PMI_HowNet_best	2 972	1 677	0.752	0.898	0.825
Word2Vec_HowNet_best	1 636	2 900	0.736	0.946	0.841
MajorityVoteRule_Lexicon	2 805	2 676	0.733	0.965	0.849
AMVR_Lexicon	4 317	4 082	0.771	0.953	0.862

第 4 组 MajorityVoteRule_Lexicon 表示使用传统投票法规则的基于 PMI 和 Word2Vec 方法生成的词典，平均准确率为 0.849。第 5 组 AMVR_Lexicon 代表使用本文提出的 Adjusted Majority Vote Rule 的基于 PMI

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

和 Word2Vec 方法生成的情感词典。其准确率达到最高的 0.862，高于第 4 组 1.3%。第 4 组和第 5 组词典的平均准确率分别高于第 1 组原始情感词典 HowNet 20.3%和 21.6%，高于第 2 组使用 PMI 得到的 PMI_HowNet_best 词典 2.4%和 3.7%，高于第 3 组使用 Word2Vec 得到的 Word2Vec_HowNet_best 词典 0.8%和 2.1%。上述结果说明综合利用 PMI 和 Word2Vec 构造情感词典能显著提高准确率，同时验证了本文提出的 AMVR 投票集成规则在识别情感词分类场景下准确率要优于传统的投票集成规则。另外，第 5 组词典的正面情感词数、负面情感词数均多于对比组 HowNet、PMI_HowNet_best、Word2Vec_HowNet_best，说明 AMVR 投票集成规则能同时准确覆盖较多的领域情感词汇。表 7 展示了使用 ARVR 集成规则构造的领域情感词典的部分情感词。

表 7　AMVR_Lexicon 情感词典部分情感词展示

分类	AMVR_Lexicon
正面词	代步 实用 多用途 性价比 经济型 耐用 小排量 限量版 粗犷 宽敞 省油 好开 智能 有面子 快 稳多
负面词	漏油 费油 抖动 震动 噪音 撞击声 裂开 裂纹 生锈 开不开 失控 冒烟 凸 低配 贵 龟速 投诉 后悔

5　结　语

针对现有情感词典自动构建过程中使用单一识别算法存在的缺点进行改进，综合点互信息和语义相似度识别新词的情感极性。情感分类对比实验表明该方法在保证准确率提升的同时，能够大幅增加识别的情感词数量。另外通过实验验证了情感词典的词性分布能够影响情感词典表现效果。

由于语料来源单一，所提出的领域情感词典扩展框架具有一定的局限性。后期计划应用于不同的业务场景，以验证这种框架在不同领域的适应性。

参考文献:

[1] Liu B. Sentiment Analysis and Opinion Mining[A]//Synthesis Lectures on Human Language Technologies[M]. Morgan & Claypool Publishers, 2012: 152-153.

[2] Hogenboom A, Heerschop B, Frasincar F, et al. Multi-lingual Support for Lexicon-based Sentiment Analysis Guided by Semantics[J]. Decision Support Systems, 2014, 62(2): 43-53.

[3] Wu F, Huang Y, Song Y, et al. Towards Building a High-quality Microblog-specific Chinese Sentiment Lexicon[J]. Decision Support Systems, 2016, 87: 39-49.

[4] Fellbaum C, Miller G. WordNet: An Electronic Lexical Database[M]. MIT Press, 1998.

[5] Stone P J, Dunphy D C, Smith M S. The General Inquirer: A Computer Approach to Content Analysis[J]. Information Storage & Retrieval, 1966, 4(4): 375-376.

[6] Dong Z, Dong Q. HowNet - A Hybrid Language and Knowledge Resource[C]// Proceedings of the 2003 International Conference on Natural Language Processing and Knowledge Engineering. 2003.

[7] 王科，夏睿. 情感词典自动构建方法综述[J]. 自动化学报，2016,42(4): 495-511. (Wang Ke, Xia Rui. A Survey on Automatical Construction Methods of Sentiment Lexicons [J]. Acta Automatica Sinica, 2016, 42(4): 495-511.)

[8] Loughran T, Mcdonald B. When is a Liability not a Liability? Textual Analysis, Dictionaries, and 10‐Ks[J]. Journal of Finance, 2011, 66(1): 35-65.

[9] Church K W, Hanks P. Word Association Norms, Mutual Information, and Lexicography[J]. Computational Linguistics, 1990, 16(1): 76-83.

[10] Turney P D, Littman M L. Measuring Praise and Criticism: Inference of Semantic Orientation from Association[J]. ACM Transactions on Information Systems, 2003, 21(4): 315-346.

[11] Deng S, Sinha A P, Zhao H. Adapting Sentiment Lexicons to Domain-Specific Social Media Texts[J]. Decision Support Systems, 2017, 94: 65-76.

[12] 郭顺利，张向先. 面向中文图书评论的情感词典构建方法研究[J]. 现代图书情报技术，2016(2): 67-74. (Guo Shunli, Zhang Xiangxian. Building Sentiment Analysis Dictionary for Chinese Book Reviews[J]. New Technology of Library and Information Service, 2016(2): 67-74.)

[13] 郁亚辉. 产品评论中领域情感词典的构建[J]. 中文信息学报，2016，30(5): 136-144. (Xi Yahui. Construction of Domain-specific Sentiment Lexicon in Product Reviews[J]. Journal of Chinese Information Processing, 2016, 30(5): 136-144.)

[14] 朱嫣岚，闵锦，周雅倩，等. 基于 HowNet 的词汇语义倾向计算[J]. 中文信息学报，2006，20(1): 14-20. （Zhu Yanlan, Min Jin, Zhou Yaqian, et al. Semantic Orientation Computing Based on HowNet [J]. Journal of Chinese Information Processing, 2006, 20(1): 14-20.)

[15] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[OL]. arXiv Preprint, arXiv:1301.378.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[16] Mikolov T, KarafiÁT M, BURGET L, et al. Recurrent Neural Network Based Language Model[C]//Proceedings of the 2010 Conference of the International Speech Communication Association, Makuhari, Chiba, Japan. 2010.

[17] 杨小平, 张中夏, 王良, 等. 基于 Word2Vec 的情感词典自动构建与优化[J]. 计算机科学, 2017, 44(1): 42-47. (Yang Xiaoping, Zhang Zhongxia, Wang Liang, et al. Automatic Construction and Optimization of Sentiment Lexicon Based on Word2Vec[J].Computer Science, 2017, 44(1): 42-47.)

[18] 王仁武, 宋家怡, 陈川宝. 基于 Word2vec 的情感分析在品牌认知中的应用研究[J]. 图书情报工作, 2017, 61(22): 6-12. (Wang Renwu, Song Jiayi, Chen Chuanbao. Application of Sentiment Analysis Based on Word2vec in Brand Cognition [J]. Library and Information Service, 2017, 61(22): 6-12.)

[19] Qiu G, Liu B, Bu J, et al. Expanding Domain Sentiment Lexicon Through Double Propagation[C]// Proceedings of the 21st International Jont Conference on Artifical Intelligence. 2009.

[20] Filho J L, Canuto A P, Santiago R N. Investigating the Impact of Selection Criteria in Dynamic Ensemble Selection Methods[J]. Expert Systems with Applications, 2018,106: 141-153.

[21] Kittler J V, Hatef M, Duin R W, et al. On Combining Classfiers[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1998, 20(3): 226-239.

[22] 黄伟, 范磊. 基于多分类器投票集成的半监督情感分类方法研究[J]. 中文信息学报, 2016, 30(2): 41-49. (Huang Wei, Fan Lei. Semi-supervised Sentiment Classification Based on Ensemble Learning with Voting[J]. Journal of Chinese Information Processing, 2016, 30(2): 41-49.)

[23] Sun Z, Song Q, Zhu X, et al. A Novel Ensemble Method for Classifying Imbalanced Data[J]. Pattern Recognition, 2015, 48(5): 1623-1637.

[24] Li Y, Guo H, Liu X, et al. Adapted Ensemble Classification Algorithm Based on Multiple Classifier System and Feature Selection for Classifying Multi-class Imbalanced Data[J]. Knowledge-Based Systems, 2016, 94: 88-104.

[25] 汽车之家论坛[EB/OL]. [2018-03-01]. https://club.autohome.com.cn/. (AutoHome Forum[EB/OL]. [2018-03-01]. https://club.autohome.com.cn/.)

[26] 结巴中文分词[CP/OL]. [2018-03-01]. https://github.com/fxsjy/jieba. (Jieba: Chinese Text Segmentation[CP/OL] . [2018-03-01]. https://github.com/fxsjy/jieba.)

[27] 搜狗词库-汽车[DB/OL]. [2018-03-01]. https://pinyin.sogou.com/dict/detail/index/15153. (Sougou Typewriting Lexicon-Car [DB/OL]. [2018-03-01]. https://pinyin.sogou. com/dict/detail/index/15153.)

[28] Chalothorn T, Ellman J. Sentiment Analysis of Web Forums: Comparison Between Sentiwordnet and Sentistrength[C]// Proceedings of the 2012 International Conference on Software Technology and Engineering. 2012.

作者贡献声明:

蒋翠清: 提出研究思路, 设计研究方案;
郭铁博, 刘尧: 分析数据;
郭铁博: 完成实验, 撰写论文;
蒋翠清, 郭铁博, 刘尧: 论文最终版本修订。

利益冲突声明:

所有作者声明不存在利益冲突关系。

支撑数据:

支撑数据由作者自存储, E-mail:guoyibo2016@163.com。
[1] 蒋翠清, 郭铁博, 刘尧. UGC_corpus.txt. 汽车评论语料数据.
[2] 郭铁博. PMI.py. PMI 实验脚本程序.
[3] 郭铁博. Word2Vec.model. 词向量输出文件.
[4] 郭铁博. SentiStrength_output.xlsx. 情感分析标记结果和输出结果文件.

收稿日期: 2018-05-23
收修改稿日期: 2018-08-23

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Constructing a Domain Sentiment Lexicon Based on Chinese Social Media Text

Jiang Cuiqing[1,2]　Guo Yibo[1]　Liu Yao[1]
[1](School of Management, Hefei University of Technology, Hefei 230009, China)
[2](Key Laboratory of Process Optimization and Intelligent Decision-making of Ministry of Education, Hefei 230009, China)

Abstract: [Objective] This study aims to construct a domain sentiment lexicon by discovering unrecognized sentiment words from user-generated contents on Chinese social media to apply it to automotive comments sentiment analysis. **[Methods]** First, words in HowNet are selected as the seeds, and PMI and Word2Vec algorithm are used to calculate the sentiment polarity of the candidates respectively on real automative corpus. Then the results of the two discriminations are judged synthetically according to the ensemble rules. Finally the proposed method was shown effective by the comparison of the sentiment classification experiments. **[Results]** The accuracy rate of the lexicon constructed according to proposed method is 21.6% higher than that of HowNet. The lexicon constructed by PMI and Word2Vec respectively increase 3.7% and 2.1%. Meanwhile the number of positive and negative emotional words are greatly increased. **[Limitations]** The source of corpus is single, and it has certain limitations in guiding other fields. **[Conclusions]** The sentiment lexicon constructed by this method can be applied to sentiment analysis of social media texts effectively.

Keywords: Social Media　Sentiment Analysis　Sentiment Lexicon　PMI　Word2Vec

欢迎订阅 2019 年《数据分析与知识发现》(月刊)

《数据分析与知识发现》杂志是由中国科学院主管、中国科学院文献情报中心主办的学术性专业期刊。刊物原名《现代图书情报技术》, 2017 年正式更名为《数据分析与知识发现》, 致力于为计算机科学、情报科学、管理学领域的研究者提供一个重要的学术交流平台。

刊物将秉承“反映前沿动态、推动学科发展、引领学术创新”的办刊理念, 广泛吸纳计算机科学、数据科学、情报科学领域的优秀研究成果, 聚焦数据驱动的语义计算、数据挖掘、知识发现、决策支持等方面的技术、方法与政策、机制。

月刊: 国际通行 16 开版本　　定价: 80 元/期, 全年定价: 960 元
国内邮发代号: 82-421　　国外邮发代号: M4345
电话/传真: 010-82624938　　地址: 北京中关村北四环西路 33 号 5D (100190)
E-mail: jishu@mail.las.ac.cn　　网址: http://www.infotech.ac.cn

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net