融合语义情感与关键词匹配的社交媒体用户社群划分研究 *

李世钰 [1] 张向先 [2] 张宇星 [3] 祝琳琳 [2] 李贺 [2]

[1] 鹏城国家实验室 深圳 518000
[2] 吉林大学商学与管理学院 长春 130012
[3] 航天档案馆 北京 100830

摘 要：[目的 / 意义] 提出一种融合语义情感分析与关键词匹配技术的社交媒体用户社群划分方法，旨在通过增加矩阵特征的数量和密度，提升基于矩阵分解的用户社群划分准确性，从而更深入地洞察社交媒体用户的兴趣和偏好。[方法 / 过程] 通过情感分析与关键词匹配构建用户态度矩阵，并将用户在社交媒体上的共同关注关系作为间接交互信息引入用户交互矩阵，以增加矩阵特征；采用 GSNMF（图正则化半监督非负矩阵分解）算法，进行用户社群的精准划分。[结果 / 结论] 研究结果表明，融合语义情感与关键词匹配技术的社群划分方法在用户社群划分的准确性和有效性方面具有显著作用。此外，结合矩阵分解得到的社群特征矩阵，能够有效分析不同社群用户的主要关注点和兴趣差异。

关键词：社群划分 语义情感 关键词匹配 矩阵分解
分类号：G203
CSTR：32305.14.CN11-1541.2025.23.003
DOI：10.13266/j.issn.0252-3116.2025.23.003
引用本文：李世钰，张向先，张宇星，等．融合语义情感与关键词匹配的社交媒体用户社群划分研究 [J]. 图书情报工作，2025, 69(23): 33-45. (Citation: Li Shiyu, Zhang Xiangxian, Zhang Yuxing, et al. Research on Social Media Community Detection Integrating Semantic Sentiment and Keywords Matching[J]. Library and Information Service, 2025, 69(23): 33-45.)

1 引言 /Introduction

随着数字化时代的到来，社交媒体已成为用户互动、信息分享和表达观点的主要平台，用户在线行为的复杂性也因此不断增加，推动了网络关系的形成与演化，进而构建出新的社会组织形式——网络社会群体 [1]。网络社会群体中的用户因其具有相似的特征和需求而在在线社交媒体中聚集，成员通过内容生产、评论、转发等社交媒体用户行为形成持续性交互 [1]。相对于将用户属性转化为结构化标签的用户画像 [2]，和因特定的共同兴趣聚集所形成的具有组织形式的兴趣小组 [3]，网络社群具有更好的自组织特性 [4]。在社群内部，成员之间通常持有更为相似的立场 [5]，高频互动行为更多 [6]，行为偏好也趋于一致 [7]。而不同群组之间的社交网络连接会更为稀疏，存在结构洞 [8]。因此，识别社交媒体中网络社群的重要意义日渐凸显。通过识别和划分社交媒体用户社群，社交媒体运营商及相关企业可以更好地理解用户，捕捉用户群体间差异，揭示用户的深层需求，使社交媒体平台以及相关企业等为用户提供更个性化和满意度更高的产品和服务。

然而，现有的社群划分方法多基于用户静态标签使用传统聚类算法 [9]，对于用户行为和交互特征的综合利用则较少，难以全面刻画用户在社群中的角色及其关系。进一步地，用户的兴趣具有多维特性，传统方法在衡量用户相似性时，缺乏对用户多维度兴趣特征的考量，从而可能产生“兴趣偏差”[10]。加之社交媒体用户之间的关系高度稀疏，进一步增加了对潜在社群结构识别的难度。如何在这种复杂情境下有效整合社交媒体用户多模态数据，提升社群划分的准确

* 本文系国家社会科学基金青年项目“认知图式视角下网络评论的影响力形成机制与评估研究”（项目编号：21CTQ015）研究成果之一。
作者简介：李世钰，博士，鹏城博士后；张向先，教授，博士，博士生导师；张宇星，助理馆员，硕士；祝琳琳，副教授，博士，硕士生导师；李贺，教授，博士，博士生导师，通信作者，E-mail：lihe200303@163.com。
收稿日期：2024-12-03 修回日期：2025-04-19 本文起止页码：33-45
版权所有 ©《图书情报工作》杂志社有限公司，未经许可不得转载（Copyrights © LIS Press Co., Ltd. Reproduction is prohibited without permission）

中国知网 https://www.cnki.net

性，是当前研究亟需解决的问题。

针对这些挑战，本研究提出一种融合语义情感与关键词匹配的社交媒体用户社群划分方法框架。该方法基于用户在社交媒体平台中的观点态度和交互信息，构建用户态度矩阵与交互矩阵，通过引入关键词匹配技术增加矩阵特征的密度，同时利用用户的共同关注信息捕捉间接关系，为社群划分提供更丰富的数据特征，减少特征稀疏所带来的影响。在此基础上，采用基于图正则化半监督非负矩阵分解（group sparsity in nonnegative matrix factorization, GSNMF）算法，融合用户的观点和交互特征，实现对用户社群的精准划分。

为了验证该方法的有效性，本研究以汽车社交媒体平台作为数据来源，通过对用户的情感表达和社交互动的深入挖掘，分析用户对不同车型产品的偏好，实现对社群的合理划分。研究通过引入语义情感与关键词匹配技术，不仅解决了社交媒体用户网络数据的稀疏性问题，还为社交媒体平台和企业提供了更准确识别用户需求、制定营销策略的实用工具。

2 国内外研究现状 /Literature review

2.1 社交媒体社群划分研究

社群划分可视作一种用户聚类，可以发现社区中的网络结构[11]，将社交网络中的用户根据某些相似性或关联性的标准划分为不同子集。利用社交媒体数据，通过数据挖掘、机器学习、社会网络分析等方法，揭示社交网络中的结构和功能，发现用户与用户间的观点、兴趣、偏好、行为等关联关系，从而识别社交媒体中的潜在用户群体。

网络社群从早期的论坛、BBS 逐步发展为以用户生成内容（UGC）为核心的社交平台[12]。因此，当前多数研究将社交媒体社群划分的工作转化为对用户发布内容进行划分，通过对用户发布内容进行主题识别来分析用户的兴趣偏好，从而实现对用户的群体划分。如董伟等利用文本聚类对用户分布结构和偏好主题内容进行了分析，识别和分析了健康社区的用户兴趣群及其相关特征[13]。江文华等通过识别图书馆研究领域的核心作者，结合识别到的作者的核心著作来构建作者研究兴趣网络，再使用 Louvain 社区发现方法对该领域研究者进行社群划分[11]。李纲等则通过构建科研社群演化路径来识别科研社群演化事件，从科研社群演化整体分析、科研社群演化路径及演化树特征分析、科研社群演化事件统计特征分析等方面揭示科研社群的动态演化模式和演化特征[14]。

也有研究关注到社交网络与用户社群划分之间的联系，J. Wang 等将主题识别和社交网络相结合进行群体推荐，通过识别社交网络中的主题并从个体和社会等因素角度计算用户与主题之间的关系来提升大规模群组推荐的预测精度[15]。张红宇等则提出了一种融合社会网络关系与用户多维特征的分组策略，以优化在线学习社区的分组效果[16]。

但总体而言，现有关于社交媒体社群划分的研究都较为依赖文本数据，对于社交媒体中用户互动行为数据的利用不足，难以全面刻画社交媒体中用户社群特征，从而可能会导致社群划分结果的社会学意义不足。同时，现有研究更多侧重于探究社交媒体中群体意见极化的生成机制，但对不同意见群体的细化识别与区分仍有待深入挖掘。

2.2 社交媒体社群划分技术方法

目前研究中社交媒体社群划分的技术涉及网络分析、数据挖掘、机器学习等多个技术领域。现有方法主要从用户偏好、社交互动数据、复杂网络结构以及属性相似性等方面出发，形成了多种分类策略。

基于社会选择和社会影响的方法利用用户的偏好信息，将其表示为群体特征，通过矩阵分解和贝叶斯个性化排序来考察社会选择和影响对用户偏好的作用。此类方法旨在揭示群体用户之间的共性与差异，以更好地实现用户与群体的分类[17]。

另一个角度的研究是基于社交互动数据的方法，该方法强调用户在社交平台上的互动行为，通过分析用户发布的帖子、评论等行为数据，识别其所属的多个社群。这种方法不依赖于社交网络的结构信息，擅长挖掘用户之间多样化的互动关系，并识别目标用户的多个社群[18]。

在复杂网络的背景下，多节点、多关系的混合网络社团划分则从网络结构出发，针对不同节点类型和关系类型对网络进行细化分类。这类方法结合了概率生成模型、元路径、种子节点、扩展模块度以及混合网络同构等概念，系统地梳理和分析了复杂社群结构的划分方式[19]。同时，基于节点距离和兴趣的划分提出了新的算法，通过计算社交网络中节点的地理距离和兴趣相似性，将节点聚类为社区。实验显示，该算法在高准确性下实现了社区检测，突出了兴趣与地理位置在社群划分中的作用[20]。

基于结构和属性相似性的策略则提出了利用网络结构信息和节点属性信息的两种算法，以提取社

中国知网 https://www.cnki.net

区。该方法将包含属性的社交图划分为社区，使得同一社区内的节点既保持密集连接，又具有属性同质性，能够从更综合的视角看待社群划分[21]。也有研究在考虑网络结构过程中利用非负矩阵分解方法对网络社区检测工作进行了探索，如金红等利用局部特征向量学习正则化矩阵代替邻接矩阵用来表达原始网络拓扑结构特征，从而解决社交网络中的稀疏矩阵问题来实现网络社区发现[22]。郑裕龙等将图卷积神经网络与非负矩阵分解方法相结合实现网络节点表示，从而提升网络社区发现的能力[23]。林晓炜等通过结构扩展，加强相邻节点结构相似性，提高节点间连接的稠密度，从而提高非负矩阵分解在社区发现中的表现[24]。

总体而言，当前社交媒体社群划分的研究仍主要依赖于用户静态标签进行聚类分析，但对用户行为特征及其互动关系的综合利用尚显不足。现有方法关注用户兴趣特征，并尝试利用属性相似性来缓解社交网络中连接稀疏性的问题。然而，研究在很大程度上缺乏对用户在感兴趣话题上的态度分析，未能充分考虑用户情感和观点的多样性，这在一定程度上限制了社群划分的精确性。

2.3 群体情感特征在社群划分中的应用研究

群际情绪理论指出，当个体认同某一社会群体时，会体验到与该群体相关的内群体和外群体的情绪反应[25]。这种群际情绪不仅影响个体对群体的态度和行为，还能够通过群体规范和认同感来调节群体内部的情绪状态[26]。因此，理解群体情绪对于社群划分和管理具有重要意义。

目前有研究表明，情感对于群体分化具有重要作用，如 R. L. Wakefield 等研究了群体认同、激情和情感两极分化对社交媒体用户群体间接近和回避倾向的影响[27]。他们以社交媒体政治团体为研究对象进行测试后发现，群体认同是导致情感两极分化加剧的重要因素，其作用机制主要在于强化对内群体的偏爱，而非增强对外群体的敌意。

也有许多研究发现，情感强度与个体对群体的认同程度正相关[28-29]。群体情感不仅影响社群内部的行为和态度，还能够用于社群的划分和推荐。例如，在社交媒体中，基于用户情感的社群划分方法可以揭示出不同社群的情感倾向，从而为社区推荐或市场策略提供支持[30-31]。此外，基于社交网络分析的方法也可以通过挖掘用户间的关联和情感倾向来划分社群，从而更好地理解社群的结构和动态[32]。

群体情感也是对特定群体间事件的主观解读结果。在同一社会事件情境下，群体成员间的情感具有趋同性，形成情感规范，而情感规范则通过社群互动进一步强化[33]。一些研究通过情感分析在图书馆阅读用户中找寻共性群体，如蔡骐等认为情感交流是阅读社群维系和增值的资本[34]。褚传弘则提出，新型读书会在读者之间重新构筑广泛的情感联结，形成了文化社群[35]。

群体情感识别也为社群划分提供了新的方法。传统的问卷调查方式耗时且成本高，而基于深度学习的群体情绪识别技术则能够实时有效地预测和分类群体情绪，如积极、中性、消极等。例如，使用深度卷积神经网络可以实现高精度的群体情绪分类，分类准确率达到 76%[36]。此外，基于图像的群体情绪识别也逐渐受到关注，通过分析人脸表情、场景特征和人体姿态等线索，可以更准确地判断群体的整体情绪状态[37]。

从以上研究可以看出，社群中的用户通常因共同的兴趣爱好或关注点而聚集，他们对特定对象的情感倾向往往具有相似性，这种情感特征在社群划分和群体行为分析中起到关键作用。当前研究已经证明，群体情感能够显著影响社群内部的行为态度和群体互动。然而，尽管情感分析在用户信息体验、谣言识别、品牌认知等领域取得了广泛应用，现有研究在将情感分析与社交媒体用户社群划分相结合方面仍相对有限。情感特征的挖掘和应用在社群划分中具有巨大潜力，有助于揭示用户的观点、态度及行为模式。

3 融合语义情感与关键词匹配的社交媒体用户社群划分方法 /Social media community detection method integrating semantic sentiment and keyword matching

3.1 社交媒体用户社群划分框架

综合国内外社交媒体用户社群划分研究现状，本研究期望通过基于语义情感分析和关键词匹配的社交媒体用户社群划分方法，弥补现有研究在用户社群划分时对于用户交互行为数据利用的不足，从而实现对社交媒体用户社群更全面且更精准的划分，为社群分析提供更丰富的信息支持。

首先，研究通过分析用户发帖内容的情感值，构建用户态度矩阵，以挖掘用户在不同话题下的情感态度特征。为提高用户态度矩阵的特征密度，在利用社交媒体预设的专业性关键词构建关键词词表的基础

中国知网 https://www.cnki.net

上，采用关键词匹配策略，从用户发帖的文本内容中匹配上下文语境相似的关键词来扩充词表。由于这些关键词直接来自用户的发帖内容，因此能够更真实地反映用户的语用习惯和情感倾向，从而显著提升用户态度矩阵的精确性与代表性。而后以词表中的关键词数量和用户个数作为用户态度矩阵的两个维度，以每个用户对于关键词的情感值作为矩阵中的特征值。

同时，为有效捕捉用户间的互动关系，研究利用用户共同关注关系构建用户交互矩阵。与传统的点赞、评论和直接关注等二元直接交互行为不同，用户的共同关注关系能够提供更丰富的间接联系信息，通过共同关注建立用户间的多元交互关系，当两个用户间具有共同关注，则将矩阵特征值设为 1，反之设为 0。由此有效缓解交互矩阵的稀疏性问题，使其更全面地反映社交网络中的互动特征。这种方式能够显著提高用户之间潜在联系的可解释性，为社群划分提供了更加丰富的语义和结构信息。

研究拟使用 GSNMF 算法进行矩阵分解，该算法可以同时得到数据集中的关键样本和关键主题两类特征，使分解结果更具有可解释性。它还可以利用已知样本的标签信息，在进行半监督学习时，使得同类样本能更好地聚类而类间距离尽可能的大[38]。因此，本研究拟通过融合用户语义情感与关键词匹配，利用 GSNMF 算法实现社交媒体用户社群划分。

图 1 展示了本研究所构建的融合语义情感与关键词匹配的社交媒体用户社群划分方法框架。该方法通过引入用户态度矩阵与用户交互矩阵，使用 GSNMF 算法实现用户社群划分。

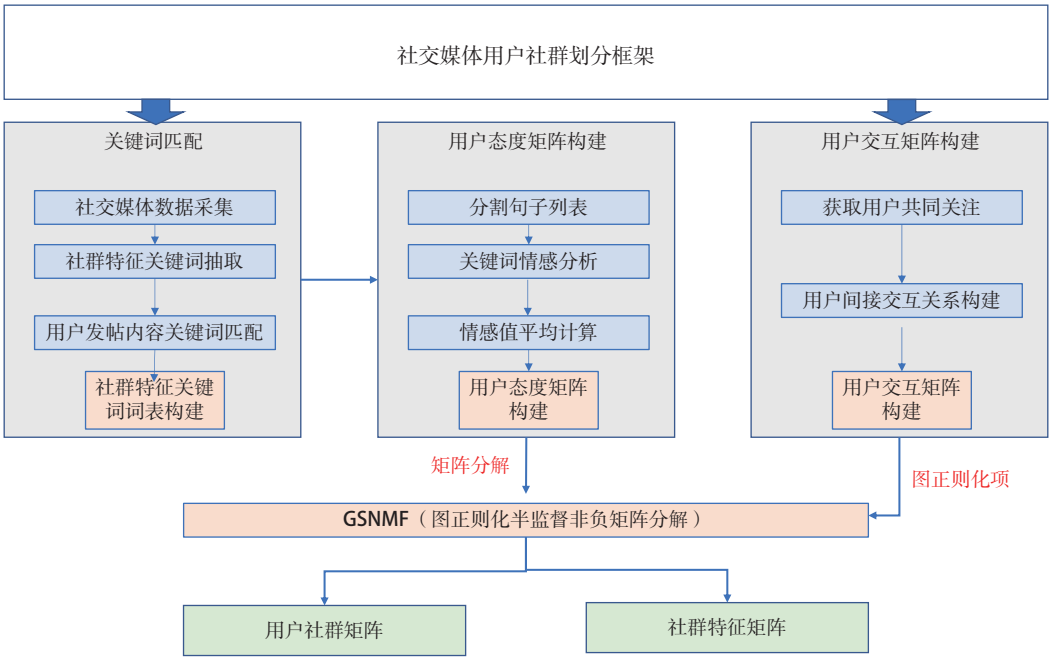


图 1　社交媒体用户社群划分方法框架

Figure 1　Framework for social media user community detection methods

3.2　基于关键词匹配的用户态度矩阵构建

为更准确地捕捉用户对社交媒体话题的情感态度，本研究通过关键词匹配扩充用户态度矩阵的特征数。用户在社交媒体中的内容中包含特定话题关键词，而情感值能有效反映用户对相关话题的态度。考虑到用户发布内容中难以涵盖用户态度矩阵中所有的关键词，本研究拟首先通过近义词匹配，从用户发帖内容中扩展用户态度矩阵的特征数量，因匹配到的关键词必然是已出现在用户已发布内容中，更加符合用户在社交媒体发布内容中的用语习惯，所以通过关键词匹配可以获取到更多的用户情感值，从而改善用户态度矩阵的稀疏性。

研究预先针对社交媒体话题构建关键词词表，而后将关键词存储在一个列表中，并使用 jieba 库对每条评论进行分词。考虑到用户评论中存在英文单词的可能，研究将英语单词去除复数、时态等形式，将英语单词还原为基本形式。而后遍历分词后的词汇，通过查询 WordNet 数据库，如果词汇及其近义词的关联类别词汇能够匹配词表中的关键词，则将词汇返回以扩充词表。

在扩充关键词表后，研究利用 NumPy 库创建一个初始的用户态度矩阵，其中列表示关键词，行表示不同的用户。通过遍历每个用户的评论，将每条评论按句号分割成句子列表，然后使用 Snownlp 包对每

中国知网 https://www.cnki.net

个句子中的关键表达进行情感分析，获取情感得分。对于包含关键表达的句子，将其情感得分作为用户对关键表达的态度，并在用户态度矩阵中相应位置进行累加。从而构建用户态度矩阵。

针对同一用户对同一关键表达可能有多个情感值的情况，代码对多个情感值进行平均处理，以得到最终的用户对该关键词的态度。这种做法旨在构建更丰富的用户情感特征，提升用户态度矩阵的表达能力，为后续的社群划分提供基础。

3.3 基于共同关注的用户交互矩阵构建

考虑到在社交媒体中，用户通常关注的是更具有影响力的账户，如大 V、公共账号等，而普通用户之间虽可能具有相似的兴趣点，但互相之间的直接关注较少。本研究利用用户共同关注的在线社区及账号形成用户的间接交互，构建用户交互矩阵。通过考虑用户之间是否存在共同关注，进一步提升了用户交互矩阵的数据特征密度。这种方式可以更好的囊括用户的共同兴趣点，从而展现社交网络中普通用户之间的潜在联系，同时也通过提升用户交互矩阵的数据特征密度来提升用户交互矩阵的表达能力，为后续的社群划分提供更为丰富的数据依据。

本研究利用 python 代码，创建一个空的用户交互矩阵，代码遍历每一对用户，检查他们是否存在共同关注的话题或账号。如果两个用户存在共同关注，则在用户交互矩阵中相应位置设为 1，表示存在间接交互关系，反之设置为 0。用户间的潜在联系得以通过共同关注呈现，增强了交互矩阵的表达能力。借助 GSNMF 算法，用户交互矩阵提供了所需的社交网络结构信息，以计算图正则化项，确保模型学习到的社群结构与真实社交网络结构保持一致，为准确划分用户社群奠定了基础。

3.4 基于非负矩阵分解的用户社群划分

在社交媒体分析中，识别用户社群并揭示用户之间的潜在联系是一个关键研究任务。本研究拟使用 GSNMF 算法进行矩阵分解，将用户态度矩阵分解为两个低秩矩阵：用户—社群矩阵 W 和社群—行为特征矩阵 H。用户—社群矩阵描述了每个用户在潜在社群中的隶属关系。矩阵中的元素和结构能够反映用户与社群之间的关联程度，从而有效描述用户在不同社群中的隶属度。而社群—行为特征矩阵则揭示各社群在不同行为特征上的代表性。在社群—行为特征矩阵中，矩阵的行表示社群，列表示行为关键词特征。社群—行为特征矩阵中的元素表示社群对行为特征的权重或贡献度。因此，社群—行为特征矩阵的每一行向量代表了对应社群中各个关键词的占比或重要性。通过这种方式，非负矩阵分解能够有效挖掘用户之间的相似性以及社群的行为模式。

算法首先随机初始化两个非负矩阵 W 和 H，其中 W 的大小是用户数乘以社群数，H 的大小是特征数乘以社群数。在用户—社群矩阵 W 的计算中，通过固定社群特征矩阵 H，使用梯度下降方法最小化损失函数来更新用户社群矩阵。损失函数包括两部分：①用户态度矩阵 X 与用户—社群矩阵 W 的乘积；②社群—成员矩阵 Z 与用户—社群矩阵 W 的乘积，同时也包括了正则化项。同样，社群—行为特征矩阵 H 的计算也需固定用户—社群矩阵 W，使用梯度下降方法最小化包含用户态度矩阵 X 与社群—行为特征矩阵 H 的乘积以及社群—行为特征矩阵 H 的平滑性正则化项的损失函数。本研究通过用户社群矩阵 W 和社群特征矩阵 H 的矩阵特征计算结果来获得每个单独用户在不同社群中所属的概率以及各个社群特征在不同社群中所占的权重，从而实现用户社群划分以及社群主要特征分析。

而用户交互矩阵 I 则为 GSNMF 方法提供了计算图正则化项所需的社交网络结构信息。通过计算结构信息中每个用户的度来计算图正则化矩阵，用以引入社交网络结构信息，以保持模型学到的社区结构与真实社交网络结构相一致，从而提升了社群识别的准确性和可靠性。

同时，本研究在 GSNMF 算法中引入用户类别标签，通过用户的真实社群归属，作为监督信息来引导矩阵分解过程，从而提升社群划分的准确性和可解释性。

4 实证研究 /Empirical study

4.1 数据获取与预处理

本研究以懂车帝汽车社交媒体平台作为数据来源。懂车帝具有车友圈功能，即已购买或有某款车使用经验的用户会加入该类型车的车友圈，在其中讨论对该款车型的使用经验与感受。而车友圈中的精华帖则通常为用户发布的长文帖，通常包含用户对一款车型较为全面的评价和感受，信息丰富，可以包含更多的要点，同时也可借此作为用户社群归属的倾向性标签，用以评价最终社群划分结果的准确率。

因此本研究爬取了懂车帝中售价 30 万—40 万区间的数款知名 SUV 车型车友圈中用户发布的精华帖，

中国知网 https://www.cnki.net

其中新能源汽车包括：特斯拉 ModelY、宝马 ix3、比亚迪唐、理想 L7、问界 M7，传统油车包括：奥迪 Q5L、宝马 X3、奔驰 GLC、沃尔沃 XC60，共获得帖子 814 条，逾 142 万字，其中新能源车帖子 470 条，油车帖子 344 条。

同时，本研究分别获取了懂车帝中新能源车与传统油车车型的参数配置模块中所列出的关键词，构建了关键词表，再藉由词表中的关键词在用户所发布的精华帖的内容中进行匹配，以扩充关键词表，从而达到为用户态度矩阵提供更多数据特征的目的。

研究还获取了发布精华帖用户的关注列表，如果两名用户之间有共同关注的车型或车友圈，则视为两名用户之间对某一款车型具有类似的兴趣，即可认为二者存在间接交互，由此构建用户交互矩阵。

4.2 实验设置

4.2.1 参数设置

GSNMF 算法的基本思想是构造一个邻接图来表示数据的相似性，然后利用图拉普拉斯矩阵来度量分解后的矩阵与图结构的一致性，从而使得相似的数据在低维空间中仍然相似。GSNMF 算法的目标函数为：

$$\min_{W,H} \| V-WH \|_F^2 +\alpha \mathrm{Tr}\left(W^T LW\right)+ \beta \mathrm{Tr}\left(HLH^T\right)+\gamma \mathrm{Tr}\left(H^T MH\right) \quad \text{公式（1）}$$

其中 $\|\cdot\|_F$ 表示矩阵的 F 范数，即矩阵元素的平方和的平方根。α、β 和 γ 是正则化参数，用于平衡重构误差、图正则化项和标签正则化项的权重。L 是图拉普拉斯矩阵，根据用户交互矩阵 II 构造，具体为先计算邻接矩阵 S，其元素 S_{ij} 表示数据点 V_i 和 V_j 的相似度。再由 L=D−S 计算获得，其中 D 是对角矩阵，其对角元素为：

$$D_{ii}=\sum_{j=1}^{n} S_{ij} \quad \text{公式（2）}$$

在 GSNMF 算法的参数设置方面，分解维度 k 决定了得到的社群的数量，即将原始用户特征数据划分为多少个社群。鉴于本研究的数据特征及目标，我们将用户划分为两个社群，分别代表电车用户和油车用户，因此 k 的值设置为 2。同时在电车和油车用户中各选取 20% 作为类别标签信息，用于辅助半监督学习过程。

正则化参数 lambda 控制了图正则项在模型中的贡献度，它调节了用户关系网络（即用户间接交互信息）对最终社群划分结果的影响。在本研究中，lambda 通过交叉验证选择，尝试了从 10^1 到 10^5，以确保分解过程中的行为特征和交互信息得到合理平衡，最终选择对模型误差最小的 lambda。

迭代次数 niter 确保 GSNMF 算法能够充分收敛。在每次迭代中，模型不断优化用户—社群矩阵 W 和社群—行为特征矩阵 H，逐步降低分解误差。初始迭代次数设置为 100，以获取初步收敛效果，并在确定最佳参数 lambda 之后，通过增加最大迭代次数 max_iter 至 1 000 来保证模型的充分收敛。同时，设置收敛阈值 tol 为 10^{-4}，以判断模型是否收敛，若损失函数的变化小于 tol 则提前停止迭代，以保证计算效率。

此外，为防止矩阵更新过程中可能出现的除零错误或数值溢出，设置了一个小常数 epsilon，其值为 10^{-9}。epsilon 的引入增强了算法的数值稳定性，确保了分解过程中的计算安全。

针对 GSNMF 算法所设置的参数在用作对比的基线模型中保持一致。

4.2.2 基线模型选取

如今，非负矩阵分解的理论和方法不断发展，在各个领域得到了广泛的应用，同时也针对不同的任务产生了许多变体用于优化相关研究，研究选取图正则化非负矩阵分解（graph regularized nonnegative matrix factorization，GNMF）和深度非负矩阵分解（deep nonnegative matrix factorization，DNMF）算法作为对比模型，与GSNMF的实验结果进行对比，以验证引入用户间接关注关系图结构特征的以及半监督学习对社交媒体用户社群划分的有效性。同时，考虑到现有社群划分方法主要针对用户进行聚类分析，因此，本研究结合 K- Means、DBSCAN、谱聚类三种聚类算法作为对本文所提出社群划分方法的对比。

（1）DNMF 算法。DNMF 算法是一种深度非负矩阵分解算法 [39]，其目的是通过多层的非负矩阵分解，提取数据的层次化特征和结构。DNMF 算法的基本思想是将数据矩阵分解为 L+1 层的特征矩阵 $H_0, H_1, \cdots, H_L$，其中 $H_0=V$，H_L 是最终的低维特征，每一层的特征矩阵都可以用上一层的特征矩阵和一个基础矩阵 W_i 的乘积来近似表示，即：

$$H_{i-1} \approx W_i H_i,\ i=1, 2, \cdots, L \quad \text{公式（3）}$$

其中 W_i 和 H_i 都是非负的。DNMF 算法的优化过程一般分为两个阶段：预训练阶段和微调阶段。在预训练阶段，DNMF 算法对每一层使用单层的非负矩阵分解算法，初始化 W_i 和 H_i。在微调阶段，DNMF 算法通过反向传播，联合优化所有的 W_i 和 H_i，使得整体的重构误差最小，即：

中国知网 https://www.cnki.net

$$\min_{W_i,H_i}\sum_{i=1}^{L}\| H_{i-1}-W_iH_i \|_F^2 \qquad \text{公式（4）}$$

其中 $\|\cdot\|_F$ 表示矩阵的 F 范数，即矩阵元素的平方和的平方根。

DNMF 通过在目标函数中加入正则化项，进一步约束分解矩阵的稀疏性和平滑性，从而提升分解的稳定性和鲁棒性。然而，DNMF 的正则化多针对矩阵元素的分布与特征提取，往往忽视了社交网络中的图结构特性。相比之下，GSNMF 算法引入了图正则化，使得在分解过程中，不仅保持了矩阵的平滑性，还更好地保留了社交网络的图结构信息。因此，本研究选取 DNMF 算法作为对比模型，验证引入用户交互矩阵对于社群划分结果的有效性。

（2）GNMF 算法。GNMF 算法是由 C. Deng 等提出的一种在 NMF 的基础上引入了图正则化项的算法 [40]，其目的是在进行非负矩阵分解的同时，保持数据的局部几何结构。GNMF 算法的基本思想是构造一个邻接图来表示数据的相似性，然后利用图拉普拉斯矩阵来度量分解后的矩阵与图结构的一致性，从而使得相似的数据在低维空间中仍然相似。其目标函数为：

$$\min_{W,H}\| V-WH \|_F^2+\alpha\mathrm{Tr}\left(W^TLW\right)+\beta\mathrm{Tr}\left(HLH^T\right) \quad \text{公式（5）}$$

其中 $\|\cdot\|_F$ 表示矩阵的 F 范数，即矩阵元素的平方和的平方根。α 和 β 是正则化参数，用于平衡重构误差和图正则化项的权重。L 同样是图拉普拉斯矩阵，定义为 L=D–S。

S 是邻接矩阵，其元素 S_{ij} 表示数据点 V_i 和 V_j 的相似度。

GNMF 算法在传统 NMF 的基础上引入了图正则化项，能够保留数据的局部几何结构，使得分解结果更符合原始数据的相似性。本研究通过选取 GNMF 算法作为基线对比模型，验证 GSNMF 算法中引入半监督学习的有效性。

（3）K-Means。K-Means 是一种基于划分的经典聚类算法 [41]，其核心思想是通过迭代优化样本到簇中心的距离，将样本划分为若干个簇，使簇内样本尽可能相似而簇间差异最大。算法的主要过程包括初始化 K 个簇心、计算每个样本与簇心之间的距离、重新更新簇心直至收敛。K-Means 对于数据维度较高但结构清晰、簇形状相对规则的数据聚类表现良好，且计算效率较高。但它对初始中心敏感，且容易陷入局部最优，尤其在存在非凸分布或噪声时表现受限。

（4）DBSCAN。DBSCAN（density-based spatial clustering of applications with noise）是一种基于密度的聚类算法，能够识别任意形状的聚类结构，并天然具备发现噪声点的能力 [42]。它通过两个参数——邻域半径 eps 和最小点数 minPts 来定义“密度可达”，进而构造高密度区域。DBSCAN 不需要预先指定聚类数量，适用于密度分布不均的数据集。

（5）谱聚类。谱聚类（spectral clustering）是一种基于图论的聚类方法 [43]，其主要思想是将数据点看作图中的节点，通过构造相似度矩阵形成邻接图，并计算其拉普拉斯矩阵的特征向量，从而将数据投影到一个低维特征空间中，在该空间中再使用传统的聚类算法如 K-Means 进行聚类。谱聚类适合处理具有复杂结构的非凸数据，尤其适用于通过图结构建模的场景，如用户交互网络。然而，它依赖相似度矩阵的质量，计算复杂度较高，且对于聚类数目的选择较为敏感。

4.3 实验结果

4.3.1 关键词匹配结果

本研究从懂车帝中的“参数配置模块”中获取到了关键词 334 个，同时将作为数据获取的汽车品牌名关键词放入词表，而后将获取到的懂车帝车友圈精华帖中的帖子内容分词后与获取到的关键词进行匹配。考虑到 WordNet 库对于词汇及其近义词的关联类别词汇进行匹配，尽可能地扩大匹配类别的同时也匹配到了一些与汽车领域特性无关的词汇或符号，因此本研究对于得到的匹配结果进行了人工检测和筛选，最终得到了描述汽车领域相关新的关键词 18 个，其对应关系如表 1 所示：

表 1 关键词匹配结果
Table 1 Keyword matching result

参数配置模块关键词	匹配关键词
CLTC（中国轻型汽车行驶工况续航）	TPMS（胎压监测系统）
	EAP（召唤功能 & 自动停车系统）
	APP
长	安全 时间
	ASSIST（辅助）
EBD（电子制动力分配系统）	Adaptive（自适应模式）
	Control（中控）
	AMG（改装公司）
EBA（电子控制制动辅助系统）	AA（改装厂商）
DSC（车身稳定控制系统）	Dual（汽车空调分区控制按钮）
	NVH（噪声、振动与声振粗糙度）
	DMI（插电式混合动力汽车系统）
BA（刹车辅助系统）	Air（空气压力）
	PS（方向盘锁死指示以及转向助力系统故障提示）
	DM（双模动力汽车）
ISOFIX（儿童座椅固定装置）	SUV（越野车）
4G	电

中国知网 https://www.cnki.net

研究将以上全部关键词整合进一个词表，以用于用户态度矩阵的特征计算。

4.3.2 用户态度矩阵构建结果

用户态度矩阵的构建使得本研究可以实现社交媒体平台用户对特定关键词的态度表达。本研究利用基于自然语言处理的情感分析工具，结合用户在社交媒体上的评论数据，以获取到的关键词为列，用户为行，每个元素代表用户对应关键词的态度。

本研究通过在用户发帖内容中匹配关键词来提升用户态度矩阵特征，表 2、表 3 分别展示了对从平台获取的关键词以及匹配到的关键词进行情感分析后局部用户态度矩阵的稀疏性：

表 2 匹配关键词前用户态度矩阵（局部）
Table 2 Pre-keyword matching user attitude matrix (partial)

用户 ID	关键词		
	级别	电动机	CLTC
1886********1900	0	0.99	0
2172********5790	0.33	0	0
2365********2560	0	0	0
2938********7060	0	0.99	0
3003********4890	0.06	0	0
3214********3820	0	0	0
3267********4320	0	0	0
3536********4260	0.55	0	0
3658********8480	0.00	0	0.11
3878********0420	0	0	0

表 3 匹配关键词后用户态度矩阵（局部）
Table 3 Post-keyword matching user attitude matrix (partial)

用户ID	关键词		
	电	安全	时间
1886********1900	0.35	0.12	0.06
2172********5790	0.19	0.43	0.32
2365********2560	0.14	0	0.87
2938********7060	0.22	0.84	0.06
3003********4890	0.15	0.60	0.68
3214********3820	0.69	0.82	0.00
3267********4320	0.32	0	0
3536********4260	0.36	0.94	0
3658********8480	0.088	0.00	0
3878********0420	0.21	0.12	0.06

表 2 和表 3 选取了相同的 10 个用户分别在懂车帝参数配置模块中所获取的关键词以及根据全部用户发布帖子所匹配到关键词进行情感分析后所得到的用户态度矩阵特征值。可以看到，匹配到的关键词因为出现在用户发布帖子的内容中，相对更符合用户发帖语言习惯，因此也更容易计算得到更多的特征值，具有更高的矩阵特征密度。而从平台所获取到的关键词并不一定会被所有用户大量提到。因此，本研究通过匹配用户帖子的关键词改善了用户态度矩阵的稀疏性。

4.3.3 用户交互矩阵构建结果

本研究通过用户之间的共同关注，捕捉用户的间接交互关系，从而构建用户交互矩阵。该矩阵以用户 ID 为行和列，其中各元素表示响应用户之间是否存在间接交互关系，以 1 表示存在交互，0 表示不存在交互。以“新能源车用户”和“传统油车用户”两大群体为例，对 814 名用户进行了交互矩阵的构建。

在构建用户交互矩阵的过程中，深入分析了用户在社交媒体平台上的互动行为，通过解析评论、消息、分享等内容，判断用户之间的交互关系。本研究分别选取了部分新能源车用户与传统油车用户绘制了用户间接交互图以表示用户之间的间接交互情况，如图 2 所示。其中蓝色的点表示新能源车用户的间接交互关系，而红色的点则表示传统油车用户，如果两名用户之间存在间接交互关系则在两个节点间添加连线。能够看到，图 2 中同种颜色的节点之间连线更多，导致图中边缘连线更为密集，而中间较为稀疏，充分表明了引入用户间接交互矩阵能够为用户社群划分提供较好的数据特征支撑。

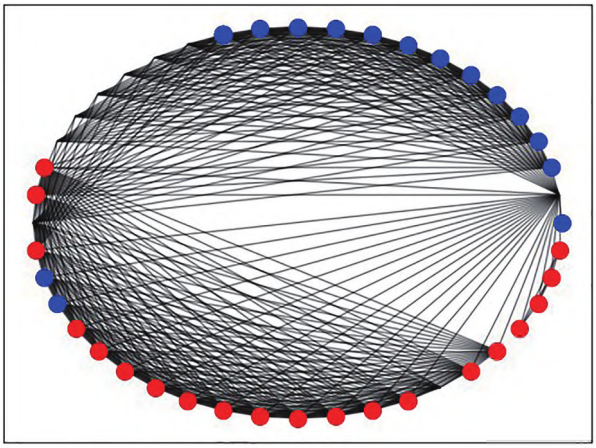


图 2 用户间接交互图
Figure 2 User indirect interaction graph

4.3.4 用户社群划分结果

图 3 展现了 3 种矩阵分解方法在经关键词匹配后、关键词匹配之前以及只使用用户之间的直接关注关系的特征输入下进行社群划分的准确率。本研究使用 GSNMF、GNMF 和 DNMF 等矩阵分解算法，对 814 名用户进行了社群划分，计算了每个用户分别隶属于“新能源车用户”或“传统油车用户”的概率。通过判断用户在两类社群中的归属概率，将其划分

中国知网 https://www.cnki.net

到隶属概率较大的一类社群中，从而获得用户的社群分类结果。接着，根据用户实际拥有的车型信息，为其分配“新能源车用户”或“传统油车用户”的标签，以此来评估各类矩阵分解算法的准确性。

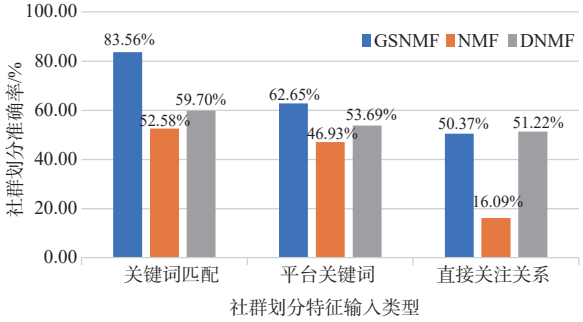


图 3 矩阵分解方法社群划分准确率

Figure 3 Community detection accuracy via matrix factorization

从图 3 中可以看到，GSNMF 算法在引入关键词匹配后，社群划分的准确率达到了 83.56%，相较于 GNMF(52.83%)和 DNMF(59.70%)的表现更为出色，显著提升了用户社群划分的准确性。这表明 GSNMF 通过关键词匹配有效地捕捉了用户在社交网络中的兴趣态度，为社群划分提供了良好的辅助作用。

在三种矩阵分解方法中，引入关键词匹配策略明显提高了矩阵特征密度，相较于仅使用平台提供的关键词或直接关注关系，这种特征处理方式显著提升了社群划分的准确率。其中，GSNMF 算法在加入关键词匹配后准确率提升幅度最大，表明关键词匹配策略为用户社群划分提供了更丰富的数据特征，提高了分类判断的精度。

而从只使用用户间直接关注关系的计算结果来看，各种矩阵分解方法的准确率普遍较低。这反映出仅利用直接关注关系进行社群划分，难以充分揭示用户之间的真实兴趣关联，导致分类效果不佳。

在与传统聚类方法的对比中，研究分别在不同的特征结构上展开聚类分析。考虑到以往研究中存在将情感特征与用户行为特征连接从而进行聚类的做法，本研究面向 K-Means 和 DBSCAN 聚类算法分别使用了“态度矩阵”与“交互矩阵＋态度矩阵”的联合特征，谱聚类则由于其图论基础，专门用于对用户间“交互矩阵”构成的邻接图进行社群划分。

在聚类方法准确率的计算方式上，本研究采用“主类对齐法”进行评估，即根据前 469 名用户和后 345 名用户所代表的两个真实社群，统计聚类结果中这两组用户分别在各自主聚类中的占比情况。准确率定义为聚类标签与真实标签最优对齐后分类正确的样本占比情况如表 4 所示：

表 4 与聚类方法社群划分准确率对比

Table 4 Comparison of community detection accuracy with clustering methods

方法	使用特征	准确率 /%
GSNMF	交互矩阵＋态度矩阵	83.56
K-Means	交互矩阵＋态度矩阵	过拟合
K-Means	态度矩阵	57.25
DBSCAN	交互矩阵＋态度矩阵	50.00
DBSCAN	态度矩阵	45.72
谱聚类	交互矩阵	57.99

表 4 的结果表明，本研究提出的社交媒体用户社群划分框架在聚类准确率结果上具有明显优势。相比之下，K-Means 在仅使用态度特征时准确率仅为 57.25%，因 DBSCAN 无法提前限定聚类数为 2，所以即便在“主类对齐法”情况下，其在联合特征和态度特征下的准确率分别为 50.00% 和 45.72%，不高于 50.00%。谱聚类在交互矩阵上的表现为 57.99%，说明传统聚类方法在面对复杂多维的社交媒体数据时存在结构感知能力弱、模型鲁棒性差等问题。

特别是 K-Means 在使用交互矩阵与态度矩阵联合特征进行聚类时出现了“过拟合”现象。通过轮廓系数和维度压缩实验可以发现，该模型在高维特征空间中捕捉的是维度冗余导致的伪分界，从而无法真实反映社群的内在结构。这一结果进一步说明，在特征维度过高时，传统聚类方法如 K-Means 并不具备良好的泛化能力，容易受到噪声维度和特征共线性的影响。

同时，对于各种方法来说，引入关键词匹配提升矩阵特征密度和用户间接交互关系后，社群划分准确率相较于关键词匹配之前均有所提升，且以 GSNMF 算法提升更为显著。可见，关键词匹配和用户间接关注关系为用户社群划分提供了更多的数据特征，提升了用户的分类判断准确率。

GSNMF 算法通过考虑用户态度矩阵和社群成员矩阵的乘积，以及通过乘法更新规则来优化社群特征矩阵，使得用户态度矩阵可以通过社群成员矩阵和社群特征矩阵的转置来进行近似重构，因此算法在得到社群成员矩阵判断用户隶属社群概率的同时，还可以得到社群特征矩阵，在本研究中表现为所得到的关键词在不同社群中的隶属权重。利用此权重，若某一关键词在不同社群中隶属的权重差值较大，则可认为该关键词在某一类社群中相对更加被用户重视。

表 5、表 6 分别展示了利用 GSNMF 算法进行分

中国知网 https://www.cnki.net

解所得到的社群—行为特征矩阵所体现出的新能源车用户与传统油车用户社群中权重占比差值大于 5 的关键词，及其在各社群中具有更高的影响力。结合矩阵分解结果可以得出，主动降噪、ABS 防抱死、OTA（空中下载技术）、哨兵模式、陡坡缓降、座椅电动调节、HUD（抬头显示）、自动驻车、车道居中保持、隐藏式门把手等关键词在新能源车用户在社群中权重占比较大，这些词也较好体现了新能源车所展现的新型造车技术革新能力。而运动风格座椅、电动车窗、发动机、中控、驾驶模式选择、变速箱、BA（刹车辅助系统）、长、宽、高等词同样体现了传统油车用户对于油车传统性能评价角度的重视。

表 5　新能源车用户高权重差值关键词
Table 5　High-weight differential keywords of new energy vehicle users

关键词	权重差值
主动降噪	12.22
ABS 防抱死	9.98
OTA 升级	9.23
哨兵模式	7.48
OTA 版本	7.10
陡坡缓降	6.48
座椅电动调节	6.06
HUD	5.96
自动驻车	5.88
车道居中保持	5.11
隐藏式门把手	5.11

表 6　传统油车用户高权重差值关键词
Table 6　High-weight differential keywords of internal combustion engine vehicle users

关键词	权重差值
BA（刹车辅助系统）	15.37
变速箱	14.86
驾驶模式选择	8.57
长	7.92
中控	7.54
宽	7.22
发动机	6.99
电动车窗	6.77
运动风格座椅	5.04

5　结论与展望 /Conclusion and prospect

5.1　研究结论

本研究所提出的采用 GSNMF 矩阵分解算法，融合语义情感与关键词匹配的社交媒体用户社群划分方法框架，实现了汽车社交媒体环境下用户社群的较高精度划分。相较于传统使用用户静态标签进行聚类的社群划分方法，本研究所使用方法充分考虑了用户情感信息与用户间交互信息，以更丰富的信息和密度更大的矩阵特征完成了社交媒体用户社群划分任务。该方法在用户社群划分准确率方面达到了 83.56%，显著高于 GNMF 与 DNMF 以及传统聚类方法的计算结果，证明了研究所提出的社交媒体用户社群划分框架的可行性以及引入用户间接关注关系和关键词情感对于用户社群划分的有效性。

同时，关键词匹配显著增大了用户态度矩阵的数据特征密度，这有助于提升社群划分的准确率。匹配到的关键词能够更贴合用户的语言习惯，从而更准确的反映用户在社交媒体中的关注兴趣点。由社群划分准确率可以看出，无论是 GSNMF 算法，还是用作对比的 GNMF 与 DNMF 算法，在进行关键词匹配提升矩阵数据特征后，社群划分准确率都有所提升，且以 GSNMF 算法效果提升最为显著。

本研究还在社群划分过程中引入了用户间接交互矩阵，对于社交媒体来说，具有相同兴趣爱好或观点的用户，尤其是普通用户之间难以具有直接的点赞、评论、转发等交互，相对来说，用户对于大 V、超话等一类的高影响力账号和内容具有共同关注的发生可能性更高 [45]。因此，本研究通过考虑用户的间接交互提升了用户交互矩阵数据特征密度，更好地保证同类社群用户之间的联系表征，同样有助于提升社群划分结果的准确性。

根据矩阵分解所得到的社区特征矩阵结果，研究还发现了新能源车和传统油车在社群中的关键词权重占比存在显著差异。可以看到，对于新能源车来说，持续实现技术创新是推动其持续发展的关键。新能源车社群中的关键词如“主动降噪”“OTA”“哨兵模式”等均体现出了当前汽车行业的技术快速革新能力，更体现出消费者对驾驶安全和舒适性的更高要求。因此，新能源车在未来的发展中，应更加注重技术创新，不断推出更先进、更实用的技术，以满足消费者对高品质驾驶体验的要求。而对于传统油车社群来说，“发动机”“变速箱”体现出消费者对传统车型性能的重视。因此，传统油车车型在未来应更加注重展现其性能优越性。而“中控”等词的出现同样提醒传统车企需要注重技术更新能力，注重性能与技术的全方位融合。

5.2　未来研究方向

本研究仍存在一些局限性。在关键词匹配过程中，尽管使用了 WordNet 库进行关联类别词汇匹配，

中国知网 https://www.cnki.net

但考虑到汽车类社交媒体的特性，仍然可能存在某些词汇与用户习惯性语言的偏差或模糊性。因此，在未来应该考虑进一步提升关键词匹配的准确性和全面性。

同时，研究在未来考虑融合多模态信息，如文本、图像和音视频等内容，以更全面的把握社交媒体中用户的行为和兴趣，以提高模型对用户多维度行为的理解能力，增强社交媒体用户社群划分的准确性。

在未来的社群划分工作中，还拟考虑社交媒体用户社群划分的时序性质，开展针对社交网络中用户关系和兴趣演化的研究，以更好的捕捉社交媒体用户的变化趋势和社群演化规律，使社群划分方法更具有普适性。

参考文献 /References：

[1] 张文宏 . 网络社群的组织特征及其社会影响 [J]. 江苏行政学院学报 , 2011(4): 68-73. (ZHANG W H. Organizational characteristics and social impact of network social groups[J]. The Journal of Jiangsu Administration Institute, 2011(4): 68-73.)

[2] HU J, SHAO H, TANG J, et al. Research on reading subject recommendation of library based on data analysis[J]. Journal of physics: conference series, 2020, 1607(1): 012022(7pp).

[3] 卓玛曲松 . 探索与发现：初中数学兴趣小组活动的效果分析 [C]// 中国智慧工程研究会 . 2024 数字化教育教学交流会论文集 . 长沙 : 2024 数字化教育教学交流会 , 2025: 1-2. (ZHUOMA Q S. Exploration and discovery: Effectiveness analysis of mathematics interest group activities in junior high schools[C]// China Wisdom Engineering Association Proceedings of the 2024 Digital Education and Teaching Exchange Conference. Changsha: the 2024 Digital Education and Teaching Exchange Conference, 2025: 1-2.)

[4] 滕广青 , 贺德方 , 彭洁 , 等 . 基于 “ 用户 — 标签 ” 关系的社群知识自组织研究 [J]. 图书情报工作 , 2014, 58(20): 106-111. (TENG G Q, HE D F, PENG J, et al. Study on self-organization of community knowledge based on “user-tag” relationship[J]. Library and information service, 2014, 58(20): 106-111.)

[5] KETS W S A. A belief-based theory of homophily[J]. Games and economic behavior, 2019, 115: 410-435.

[6] 李贺 , 刘嘉宇 , 沈旺 , 等 . 社交参与视角下超图增强的学习趣缘社群群体检测研究 [J]. 情报学报 , 2024, 43(12): 1425-1439. (LI H, LIU J Y, SHEN W, et al. Group detection in interest-based learning communities enhanced by hypergraph from a social engagement perspective[J]. Journal of the China Society for Scientific and Technical Information, 2024, 43(12): 1425-1439.)

[7] OOMS W, BELL J, KOK R A W. Use of social media in inbound open innovation: building capabilities for absorptive capacity[J]. Creativity and Innovation Management, 2015, 24(1): 136-150.

[8] SAH P, MANN J, BANSAL S. Disease implications of animal social network structure: a synthesis across social systems[J]. Journal of animal ecology, 2018, 87(3): 546-558.

[9] IBRAHEEM S F, AL-SARRAY B. A review of community detection based on modularity optimization in complex networks[J]. Iraqi journal of science, 2024, 65(5): 2775-2793.

[10] 孙赛赛 , 何雅迪 , 王兰 . 青年群体网络 “ 圈层化 ” 的样态透视与应对之策 [J]. 理论观察 , 2024(4): 95-98. (SUN S S, HE Y D, WANG L. The perspective and countermeasures of the “circle like” network of youth groups [J]. Theoretic observation, 2024(4): 95-98.)

[11] 江文华 , 徐健 , 李纲 , 等 . 基于研究兴趣相似性网络的我国图书馆学研究社群分析 [J]. 现代情报 , 2019, 39(9): 21-27. (JIANG W H, XU J, LI G, et al. Analysis on domestic research community of library science based on research interest similarity network[J]. Journal of modern information, 2019, 39(9): 21-27.)

[12] 邓胜利 , 胡吉明 . Web 2.0 环境下网络社群理论研究综述 [J]. 中国图书馆学报 , 2010(5): 90-95. (DENG S L, HU J M. Review on online community theory in web2.0 environment[J]. Journal of library science in China, 2010(5): 90-95.)

[13] 董伟 , 陶金虎 . 基于主题偏好的在线健康社区用户兴趣群体识别研究 —— 以医享网为例 [J]. 情报科学 , 2021, 39(3): 88-93, 119. (DONG W, TAO J H. Research on user interest group identification in online health communities based on theme preferences: a case study of Yixiang network[J]. Information science, 2021, 39(3): 88-93, 119.)

[14] 李纲 , 唐晶 , 毛进 , 等 . 基于演化事件探测的学科领域科研社群演化特征研究 —— 以图书馆学情报学为例 [J]. 图书情报工作 , 2021, 65(17): 79-90. (LI G, TANG J, MAO J, et al. Research on the evolution characteristics of scientific research communities in subject fields based on evolutionary event detection: an example of LIS[J]. Library and information service, 2021, 65(17): 79-90.)

[15] WANG J, LIU Z, ZHAO H. Group recommendation using topic identification in social networks[C]//2014 sixth international conference on intelligent human-machine systems and cybernetics. Hangzhou: IEEE, 2014, 1: 355-358.

[16] 张红宇 , 王坚强 , 马华 . 结合社会网络分析和多维特征聚类的学习小组划分方法 [J]. 计算机应用研究 , 2013, 30(3): 732-735, 741. (ZHANG H Y, WANG J Q, MA H. Grouping approach of learning team based on social network analysis and multidimensional feature clustering [J]. Application research of computers, 2013, 30(3): 732-735, 741.)

[17] 何军 , 刘业政 , 王锦坤 . 基于社会选择和社会影响的社交网络社群分类与群推荐策略研究 [J]. 现代情报 , 2018, 38(1): 92-99. (HE J, LIU Y Z, WANG J K. Community classification and

中国知网 https://www.cnki.net

group recommendation strategy of online social networks based on social selection and social influence[J]. Journal of modern information, 2018, 38(1): 92-99.)

[18] CHEN Y L, CHUANG C H, CHIU Y T. Community detection based on social interactions in a social network[J]. Journal of the Association for Information Science & Technology, 2014, 65(3): 539-550.

[19] 蒋璐 , 陈云伟 . 多节点多关系的混合网络社团划分研究综述 [J]. 图书情报工作 , 2021, 65(19): 142-150. (JIANG L, CHEN Y W. A review of community detection in hybrid networks with multiple nodes and multiple relationships[J]. Library and information service, 2021, 65(19): 142-150.)

[20] HUTAIR M B, AGHBARI Z A, KAMEL I. Social community detection based on node distance and interest[C]//Proceedings of the 3rd IEEE/ACM international conference on big data computing, applications and technologies. Shanghai: IEEE, 2016: 274-289.

[21] DANG T A, VIENNET E. Community detection based on structural and attribute similarities[J]. Achi, 2012, 659: 7-12.

[22] 金红 , 胡智群 . 基于非负矩阵分解的稀疏网络社区发现算法 [J]. 电子学报 , 2023, 51(10): 2950-2959. (JIN H, HU Z Q. The non-negative matrix factorization based algorithm for community detection in sparse networks[J]. Acta electronica sinica, 2023(10): 2023, 51(10): 2950-2959.)

[23] 郑裕龙 , 陈启买 , 贺超波 , 等 . 图卷积网络增强的非负矩阵分解社区发现方法 [J]. 计算机工程与应用 , 2022, 58(11): 73-83. (ZHENG Y L, CHEN Q M, HE C B, et al. Nonnegative matrix factorization community detection method enhanced by graph convolutional network[J]. Computer engineering and applications, 2022, 58(11): 73-83.)

[24] 林晓炜 , 陈黎飞 . 结构扩展的非负矩阵分解社区发现算法 [J]. 山东大学学报 (工学版), 2021, 51(2): 57-64, 73. (LIN X W, CHEN L F. Community detection using nonnegative matrix factorization with structure extension [J]. Journal of Shandong University (engineering science), 2021, 51(2): 57-64, 73.)

[25] 刘峰 , 佐斌 . 群际情绪理论及其研究 [J]. 心理科学进展 , 2010, 18(6): 940-947. (LIU F, ZUO B. Intergroup emotions theory and the researches[J]. Advances in psychological science, 2010, 18(6): 940-947.)

[26] MACKIE D M, SMITH E R, BANERJI I, et al. Group-based emotion processes generalize across group exemplars and types[J]. Group processes & intergroup relations, 2024, 27(4): 925-945.

[27] WAKEFIELD R L, WAKEFIELD K. The antecedents and consequences of intergroup affective polarisation on social media[J]. Information systems journal, 2023, 33(3): 640-668.

[28] FIGUEIREDO A, VALENTIM J P, DOOSJE B. Theories on intergroup relations and emotions: a theoretical overview[J]. Psychologica, 2014, 57(2): 7-33.

[29] GOLDENBERG A, GARCIA D, SURI G, et al. Collective emotions[J]. Current directions in psychological science, 2020, 29(2): 154-160.

[30] 张梦瑶 , 朱广丽 , 张顺香 , 等 . 基于情感分析的微博热点话题用户群体划分模型 [J]. 数据分析与知识发现 , 2021, 5(2): 43-49. (ZHANG M Y, ZHU G L, ZHANG S X, et al. Grouping microblog users of trending topics based on sentiment analysis[J]. Data analysis and knowledge discovery, 2021, 5(2): 43–49.)

[31] NGUYEN T, PHUNG D, ADAMS B, et al. A sentiment-aware approach to community formation in social media[C]// Proceedings of the international AAAI conference on Web and social media. Oxford: AAAI, 2012, 6(1): 527-530.

[32] 李威 . 基于社交网络分析的用户群情感倾向研究 [D]. 武汉 : 华中师范大学 , 2019. (LI W. Research on the emotional tendency of user groups based on social network analysis[D]. Wuhan: Central China Normal University, 2019.)

[33] MACKIE D M, SMITH E R, BANERJI I, et al. Group-based emotion processes generalize across group exemplars and types[J]. Group processes & intergroup relations, 2024, 27(4): 925-945.

[34] 蔡骐 , 翁丽玲 . 情感视域下的阅读社群研究 [J]. 中国编辑 , 2020(11): 16-20. (CAI Q, WENG L L. Research on reading communities from the perspective of sentiment[J]. Chinese editorials, 2020(11): 16-20.)

[35] 褚传弘 . 身体漫游、朗读仪式与文化社群 —— 新型城市读书会的地方情感研究 [J]. 阅江学刊 , 2021, 13(2): 108-118, 123. (CHU C H. Body roaming, reading ceremony and cultural community: research on the local emotion of the new urban reading club[J]. Yuejiang academic journal, 2021, 13(2): 108-118, 123.)

[36] 王昊懿 . 群体情绪分类方法的研究与实现 [D]. 西安 : 西安电子科技大学 , 2021. (WANG H Y. Research and implementation of group-level emotion classification method[D]. Xian: Xidian University, 2021.)

[37] 高帅鹏 , 王怡凡 . 基于图像的群体情绪识别综述 [J]. 计算机与现代化 , 2024(8): 98-107. (GAO S P, WANG Y F. Survey on group-level emotion recognition in images. computer and modernization, 2024(8): 98-107.)

[38] 杜世强 , 石玉清 , 王维兰 , 等 . 基于图正则化的半监督非负矩阵分解 [J]. 计算机工程与应用 , 2012, 48(36): 194-200. (DU S Q, SHI Y Q, WANG W L, et al. Graph regularized-based semi-supervised non-negative matrix factorization[J]. Computer engineering and applications, 2012, 48(36): 194-200.)

[39] TRIGEORGIS G, BOUSMALIS K, ZAFEIRIOU S, et al. A deep matrix factorization method for learning attribute representations[J]. IEEE transactions on pattern analysis and

中国知网 https://www.cnki.net

machine intelligence, 2016, 39(3): 417-429.

[40] DENG C, HE XF, HAN JW, et al. 2011. Graph regularized nonnegative matrix factorization for data representation. [J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 33(8): 1548-1560.

[41] MACQUEEN J. Some methods of classification and analysis of multivariate observations[C]// Proceedings of the fifth Berkeley symposium on mathematical statistics and probability, volume I: statistics. Berkeley: University of California Press, 1967: 281-297.

[42] ESTER M, KRIEGEL H P, SANDER J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//kdd. 1996, 96(34): 226-231.

[43] NG A Y, JORDAN M I, WEISS Y. On spectral clustering: analysis and an algorithm [J]. Advances in neural information processing systems, 2001, 14: 849-856.

[44] 高大菊 . 基于计算机大数据分析的社交媒体用户行为挖掘与情感分析研究 [J]. 信息记录材料 , 2024, 25(10): 118-120. (GAO D J. Research on social media user behavior mining and sentiment analysis based on computer big data analysis[J]. Information recording materials, 2024, 25(10): 118-120.)

[45] JIANG J, WANG L. A study of the influence of different opinion leaders on the evolution of followers' views in social e-commerce networks[C]//2021 20th international symposium on distributed computing and applications for business engineering and science. Nanning: IEEE, 2021: 49-52.

作者贡献说明 /Author contributions：

李世钰：负责数据处理与论文撰写；

张向先：确定论文选题；

张宇星：制定论文框架；

祝琳琳：提出社群划分方法；

李贺：负责写作指导与最终定稿。

Research on Social Media Community Detection Integrating Semantic Sentiment and Keywords Matching*

Li Shiyu[1] Zhang Xiangxian[2] Zhang Yuxing[3] Zhu Linlin[2] Li He[2]

[1]Pengcheng National Laboratory, Shenzhen 518000

[2]School of Business and Management, Jilin University, Changchun 130012

[3]Aerospace Archives, Beijing 100830

Abstract: [Purpose/Significance] This study proposes a social media community detection method that integrates semantic sentiment analysis and keyword matching. By increasing the number and density of matrix features, the accuracy of user community detection based on matrix decomposition is improved, enabling deeper insights into social media users' interests and preferences. **[Method/Process]** The study constructed a user attitude matrix through sentiment analysis and with keyword matching. To enrich the matrix features, users' common followings on social media as indirect interactions were introduced into the user interaction matrix. The GSNMF (Graph Regularized Semi-Nonnegative Matrix Factorization) algorithm was used to achieve precise user community detection. **[Result/Conclusion]** The results show that the method combining semantic sentiment and keyword matching techniques significantly improves the accuracy and effectiveness of user community detection. Additionally, by leveraging the community feature matrix obtained through matrix decomposition, the major interests and preferences of different community users can be effectively analyzed.

Keywords: community detection semantic sentiment keyword matching matrix factorization

*This work is supported by the youth project of National Social Science Fund of China titled, "Research on the Formation Mechanism and Evaluation of the Influence of Online Reviews from the Perspective of Cognitive Schemas" (Grant No. 21CTQ015).

Author(s): Li Shiyu, PhD, Pengcheng Postdoc; Zhang Xiangxian, Professor, PhD, Doctoral Supervisor; Zhang Yuxing, Assistant Librarian, Master's Degree; Zhu Linlin, PhD, Associate Professor, Master's Supervisor; Li He, Professor, PhD, Doctoral Supervisor, Corresponding Author, E-mail: lihe200303@163.com.

Received: 2024-12-03 Revised: 2025-04-19 Pages: 33-45

中国知网 https://www.cnki.net